

대조 학습을 이용한 개인화 추천의 다양성 향상 연구
**Research for improving the diversity of personalized
recommendations using contrastive learning**

빅데이터응용학과 석사과정
안 지 호

지도교수: 김재경 교수님

Outline

- *Keywords*

- *Recommendation system*
- *Self-supervised learning*
- *Data augmentation*
- *Contrastive learning*
- *Diversity*

- Introduction
- Related work
- Methodology
- Experiment
- Implication
- Limitations & Future work

Introduction

Introduction

- CBF (컨텐츠 기반 필터링) 및 CF (협업 필터링)를 비롯한 기존의 추천 시스템은 다음과 같은 한계점이 존재함.
 - ✓ **추천의 참신성**: CBF 기법의 경우, 사용자가 초기에 선택한 제품과 유사한 특성의 제품(군)을 추천하므로, **새로운 제품**을 추천하는 것이 어려운 편임(Lops et al., 2011).
 - ✓ **데이터 분포의 불균형**: CF 기법의 경우, 타겟 사용자와 성향이 비슷한 사용자 집단이 주로 사용한 제품에 기반하여 제품을 추천함. 따라서, 추천 시스템이 사용자에게 상대적으로 **주목을 덜 받는 제품(Long-tail item)**을 추천하는 것이 힘든 경향이 있음 (Milojević, 2010).
 - 롱테일(Long-tail) 제품 중에서도, 사용자의 선호도에 부합하여 관심을 이끌게 됨으로써, 실제 구매 가능성으로 이어질 제품이 존재할 수 있음.
 - ✓ **확장성**: 사용자의 수와 제품의 종류가 많아질수록, 시간 및 공간 복잡도가 동시에 증가함. 따라서, 실시간으로 사용자에게 제품을 추천해주는 것이 힘들 수 있음(Marinho et al., 2011).

Introduction

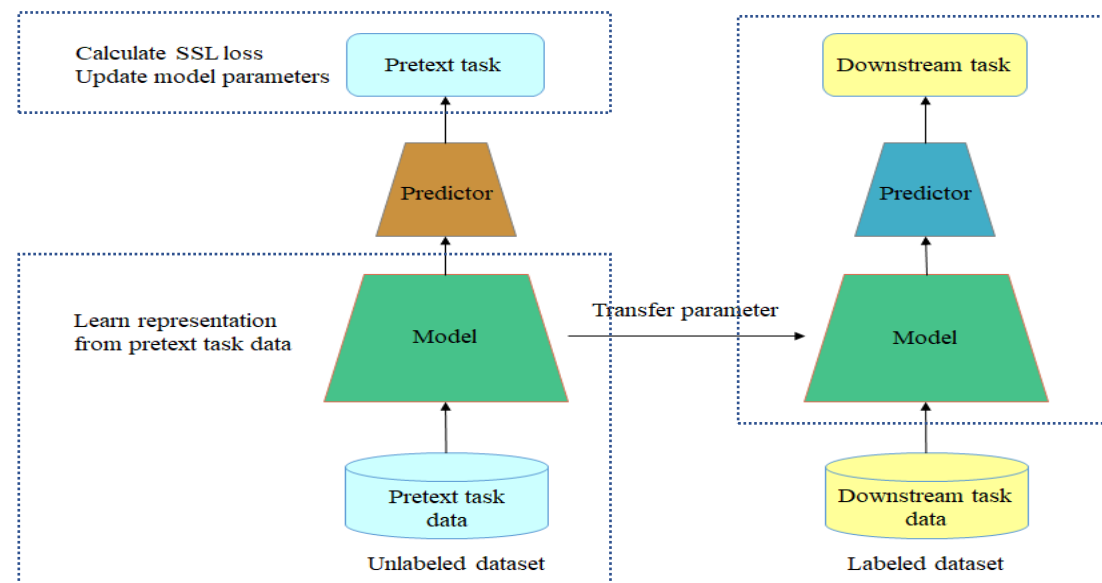
- 최근에는 앞서 제시한 문제점들을 고려하여, 추천시스템 구축에 **딥러닝 기법**을 적용하기 시작함(Zhang et al., 2019; Zhou et al., 2021).
 - ✓ 대표적으로 Neural Collaborative filtering (NCF), Wide & Deep Learning 및 DeepFM의 경우, 딥 뉴럴 네트워크를 도입함으로써 효과적으로 유저와 아이템의 임베딩 정보를 학습할 수 있게 하였음.
 - ✓ 추가적으로, 딥러닝 기반의 추천시스템 모델은 특정 객체를 보다 복합적이고 다양한 방식으로 표현할 수 있고, 비선형성을 추가함으로써 추천시스템의 성능을 크게 향상시켰음.
 - ✓ 그러나, 딥러닝 기반 추천시스템 모델을 효과적으로 학습시키기 위해서는 수 많은 양의 데이터를 획득해야 하며, 이는 비용이 매우 많이 드는 작업임(Yu et al., 2022).
 - ✓ 또한, 딥러닝 기반 추천시스템 학습에 사용되는 데이터도 대부분의 경우 소수의 인기 제품의 정보만을 포함하므로, 데이터 희소성 문제가 여전히 존재함(Sarwar, 2001; Yu et al., 2022).
-

Introduction

- 이에 자기지도 학습 방법(Self-supervised learning, SSL)을 추천 시스템에 적용함으로써, 데이터 희소성을 해결하고 추천 시스템의 성능을 향상시키는 사례가 증가하고 있음 .
 - ✓ SSL 방법론은 정답(제품 평점, 구매 여부 등)이 존재하지 않는 데이터의 특징(feature)을 추출하는 방법으로서, 추출한 특징을 바탕으로 다양한 종류의 하위 문제(제품 평점 예측, 제품 구매 여부 예측)을 효과적으로 해결할 수 있음 (L. Wu et al., 2021; Wu et al., 2020; Yu et al., 2022).

예) 생성된 제품 특성 벡터를 바탕으로,
서로 다른 제품 간 유사도를 계산

예) 제품의 정보(가격, 카테고리 등)를 이용하여
특성 벡터를 생성

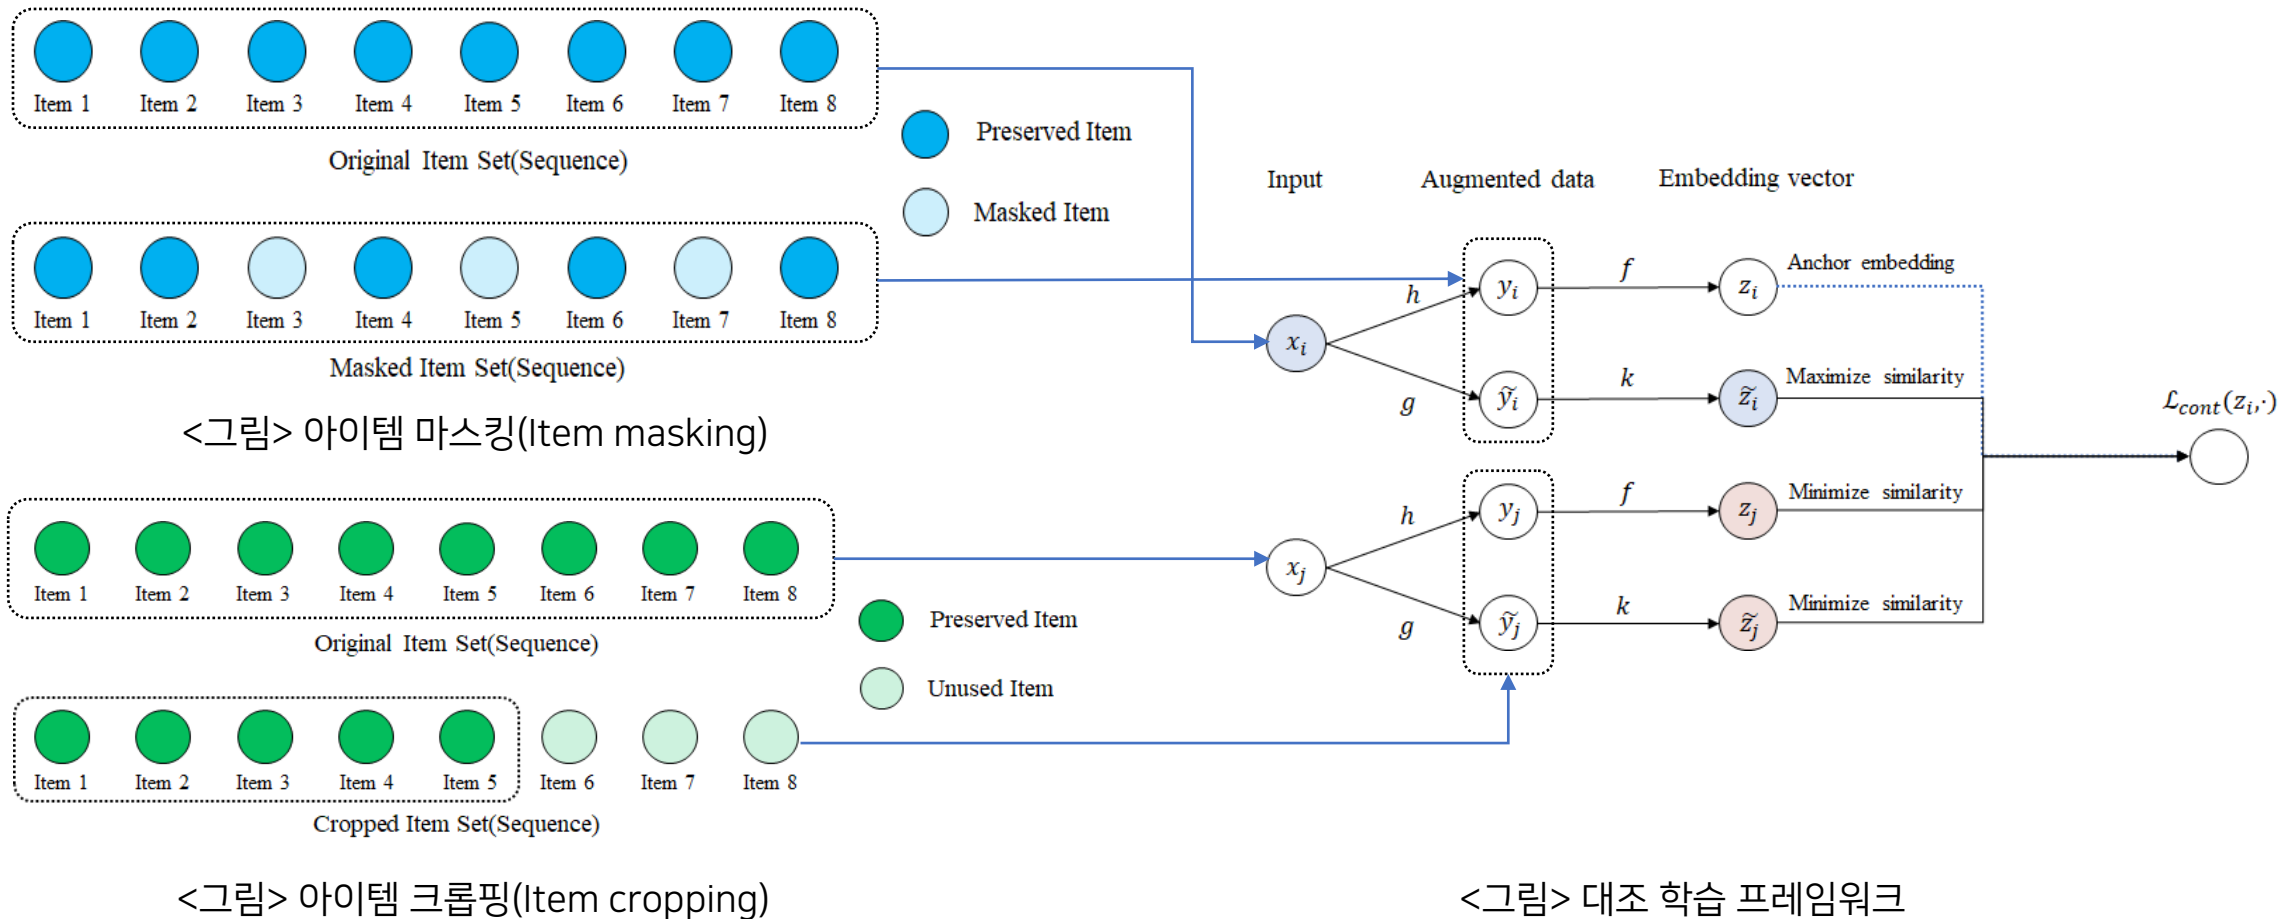


<그림> 자기지도 학습 프레임워크

Introduction

- 이때, SSL 방법론을 추천 시스템에 적용시키는 사례 중 약 42%는 **대조 학습(Contrastive learning, CL)**을 사용할 정도로, 대조 학습이 큰 비중을 차지함 (Yu et al., 2022).
 - ✓ **대조 학습**을 추천 시스템 분야에 적용함으로써, **효과적으로 제품에 대한 정보를 학습**하여 기존 추천 시스템에 비해 **높은 예측(제품 평점 예측 등) 성능**을 보여줌 (Xie et al., 2022; Yang et al., 2022).
- **대조 학습**은 원본 데이터(제품, 사용자 등)에 **데이터 증강(Data augmentation)** 방법을 적용하여 **새로운 데이터를 생성**한 후, **생성된 데이터 간의 유사성을 학습**하는 방법임 (Guan & Lam, 2022; B. Li et al., 2021).
 - ✓ 특정 사용자가 구매한 제품의 목록 중 일부 제품을 제거 또는 추출하는 방식으로 데이터를 증강할 수 있음 (Yu et al., 2022).

Introduction



Introduction

- 하지만, 대조 학습 기반 추천 시스템 연구는 **추천 시스템의 예측 정확도**를 향상시키는 데 초점을 맞추는 반면, **추천 다양성**에 대한 연구는 활발하게 진행되지 않는 경향을 보임.
- **추천 시스템에서의 다양성**은 사용자의 경험에 대한 질(Quality)을 향상시키는 데 중요한 역할을 수행함 (Kunaver & Požrl, 2017).
- 또한, 현재까지 주목을 덜 받은 롱테일 제품 중에서 사용자의 관심을 이끌고 구매를 유도할 수 있기 때문에, 추천 시스템의 **다양성을 향상**시키는 것이 매우 중요함.
- 이때, **대조 학습**을 바탕으로 제품 간의 유사성을 학습하는 과정에서, **롱테일 제품의 정보를 충분하게 학습**시킬 수 있다면, 사용자에게 보다 **다양하게 제품을 추천**해주는 것이 가능함.

Introduction

- 따라서 본 연구에서는, 제품의 평점 정보에 기반한 데이터 증강 및 자기지도 학습 방법 중 하나인 대조 학습을 추천 시스템에 적용하여, 롱테일 제품에 대하여 추천시스템의 다양성을 향상시키는 것을 목표로 함.
 - ✓ 데이터 증강(Data augmentation): 제품 평점 정보를 통해 제품 간 유사도 점수를 계산하고, 타겟 제품을 자신과 가장 유사한 제품으로 대체(substitute)하는 방법을 제안 -> 대조 학습을 위한 데이터 생성 과정
 - ✓ 대조 학습(Contrastive learning): 제품 간 유사성 학습을 통하여, 롱테일 제품 정보의 학습 기회를 증가시키고, 이에 따라 특정 사용자에게 롱테일에 속한 제품을 추천할 확률을 증가시킬 수 있도록 하는 대조 학습 프레임워크를 제안 -> 추천 다양성 개선
 - ✓ 추천시스템(Recommendation system): 대조 학습 단계에서 학습한 모델의 정보를 이용하여, 개별 사용자에게 타겟 제품에 대해 평점을 어떻게 매길 지 예측하고 그 결과를 학습함으로써, 사용자에 선호도에 부합하는 롱테일 제품을 추천할 수 있도록 하는 추천시스템 프레임워크를 제안

Related work


Related work(Self-supervised learning)

- ① 자기지도 학습(Self-supervised learning, SSL) (L. Wu et al., 2021; Wu et al., 2020)
 - 자기지도 학습(Self-Supervised Learning, SSL)은 레이블링이 되어있지 않은 데이터의 특징(feature)을 추출하는 방법으로서, 표상 학습(Representation Learning)의 일종임.
 - ✓ 자기지도 학습 과정을 Pretext task라는 용어로 표현하기도 함.
 - ✓ 레이블이 없는 데이터셋으로부터 의미있는 표현을 얻어낼 수 있다면, 이 정보들을 바탕으로 다양한 종류의 하위 문제(downstream task)을 효과적으로 해결할 수 있음 (Pourpanah et al., 2022).
 - 일반적으로, SSL 방법론은 크게 pretext task와 downstream task(primary task)의 두 가지의 단계로 구성이 됨.
 - ✓ Pretext task: 사전 학습(Pre-training) 단계라고도 부르며, downstream task를 효과적으로 해결하기 위하여 원본 데이터(raw data)를 활용하여 특정 모델로부터 self-supervision signal을 얻어내는 과정을 의미함.
 - ✓ Downstream task: 미세조정(Fine-tuning) 단계라고도 부르며, pretext task 과정에서 학습한 모델을 사용하여, 궁극적으로 해결하고자 하는 문제를 해결하는 단계임 (추천시스템, 이미지 분류 등).


Related work(Self-supervised learning)

- Calculate SSL loss
- Backward propagation
- Update weights

Learn representation
from dataset



Transfer



Fine-Tune

- Classification, Regression etc.
- Calculate Supervised task loss

Load pretrained model

- ✓ Architecture
- ✓ Weights

Related work(Data augmentation)

② 데이터 증강(Data augmentation)

- 데이터 증강은 학습 데이터가 부족한 상황을 해결하고, 학습 모델의 과적합 현상(Overfitting)을 완화시키기 위한 방법 중 하나가 될 수 있음(Mikołajczyk & Grochowski, 2018; Perez & Wang, 2017; Shorten & Khoshgoftaar, 2019).
- 또한, 데이터 증강 방법을 통해 질 좋고 일반화가 가능한 데이터 표현(representation)을 얻을 수 있다는 것도 여러 분야에서 밝혀짐(Ding et al., 2022; Li et al., 2022).
- 자기지도 추천시스템(Self-supervised Recommendation, SSL) 관점에서 주로 이용되는 데이터 증강 방법은 크게 아래 두 가지와 같음.
 - ✓ 아이템 마스킹(Item masking)
 - ✓ 아이템 크롭핑(Item cropping)

Related work(Data augmentation)

- 아이템 마스킹(Item masking)
 - ✓ 자연어 마스킹 기법 중 널리 알려진 BERT(Devlin et al., 2018)방법론과 유사하게, 특정 유저가 사용한 아이템 집합(시퀀스)이 있다고 가정할 때, 특정 비율로 아이템의 정보를 제거하는 방법임.
 - ✓ 아이템 집합 중 일부 정보를 제거할지라도, 특정 유저의 아이템 구매 의도(의향)은 남은 아이템들의 정보 속에 포함될 것이라는 관점에서 접근함(Yu et al., 2022).
 - ✓ 전체 아이템 집합(시퀀스)를 S , 전체 아이템 집합의 크기를 l , masking 비율을 α , masking이 될 아이템의 인덱스 집합을 Z , 마스킹 처리가 완료된 아이템 집합을 \tilde{S} 라고 할 때, item masking에 대한 수식을 아래와 같이 표현할 수 있음.

$$\tilde{S} = F_{mask}(S) = [\tilde{s}_1, \tilde{s}_2, \dots, \tilde{s}_l], \tilde{s}_k = \begin{cases} s_k, & k \notin Z \\ [mask], & k \in Z \end{cases}$$

$$|\tilde{S}| = (1 - \alpha) * l$$

Related work(Data augmentation)

- 아이템 크롭핑(Item cropping)
 - ✓ Item cropping 방식은, 컴퓨터 비전 분야 내에서 많이 사용되고 있는 image cropping(Caron et al., 2021; Laskin et al., 2020; Takahashi et al., 2019)을 활용한 방법으로서, 전체 아이템 집합(시퀀스)에서 부분 집합을 추출하는 방법임.
 - ✓ 특정 유저의 아이템 이용 기록의 일부분만 사용하더라도, 유저의 구체적인 프로파일(정보)의 필요 없이 추천시스템 모델로 하여금 유저의 일반화 된 표현(ex: 아이템 소비 패턴, 구매 성향 등)을 학습하도록 하는 것을 목표로 함(Yu et al., 2022).
 - ✓ 전체 아이템 집합(시퀀스)을 S , masking 비율을 α , cropping 처리가 완료된 아이템 집합을 \tilde{S} 라고 할 때, item cropping에 대한 수식을 아래와 같이 표현할 수 있음.

$$\tilde{S} = F_{mask}(S) = [\tilde{s}_k, \tilde{s}_{k+1}, \dots, \tilde{s}_{k+l-1}]$$

$$l = \lfloor \alpha * |S| \rfloor$$

Related work(Contrastive learning)

③ 대조 학습(Contrastive learning, CV)

- 대조 학습은 원본 데이터에 특정한 데이터 증강 방법을 적용하여 새로운 데이터들을 생성한 후, 생성된 데이터 간의 유사성을 학습하는 방법임.
 - ✓ **컴퓨터 비전**: 하나의 원본 이미지를 여러 각도로 회전 또는 일부 영역만 추출하여 여러 개의 이미지를 생성한 후, 생성된 사진 간의 유사도를 학습하여, 해당 지식을 객체 인식과 이미지 분류 등의 task에 적용(Guan & Lam, 2022; B. Li et al., 2021)
 - ✓ **그래프 분야**: 특정 객체(사람, 구매한 제품 등)를 표현하는 노드(node) 또는 노드 간 관계를 표현하는 간선(edge)를 임의적으로 또는 특정 기준에 따라 제거하여, 여러 개의 그래프를 생성하여 유사도를 학습하고, 해당 지식을 노드 분류 및 노드 클러스터링 등에 사용(Wang et al., 2021; You et al., 2020)

Related work(Contrastive learning)

③ 대조 학습(Contrastive learning, CV)

- 한 개의 인스턴스 (아이템, 특성, 그래프 구조 등)로부터, 데이터 증강이 완료된 여러 개의 뷰(view)를 **positive pairs**라고 정의함.
 - ✓ 또 다른 인스턴스에서 증강이 된 뷰는 **negative pair**로 정의함.
- 해당 방법론은, **positive pair** 간의 유사도는 최대한으로 하며, 반대로 **positive pair**와 **negative pair**와의 유사도는 최소화
- 본 연구에서는 대조 학습을 추천 시스템에 적용하여, 다음과 같은 효과를 얻는 것을 목표로 함.
 - ✓ 아이템 대체 기반의 데이터 증강 기법을 사용하여 대조 학습을 수행함으로써, **롱테일 제품 정보를 학습할 수 있는 기회를 증가**시킴.
 - ✓ 대조 학습을 통해 특정 사용자에게 대응하여 제품 집합 간의 유사성을 학습함으로써, **사용자에게 롱테일에 속한 제품을 추천할 수 있는 확률을 상승**시킴.

Related work(Contrastive learning)

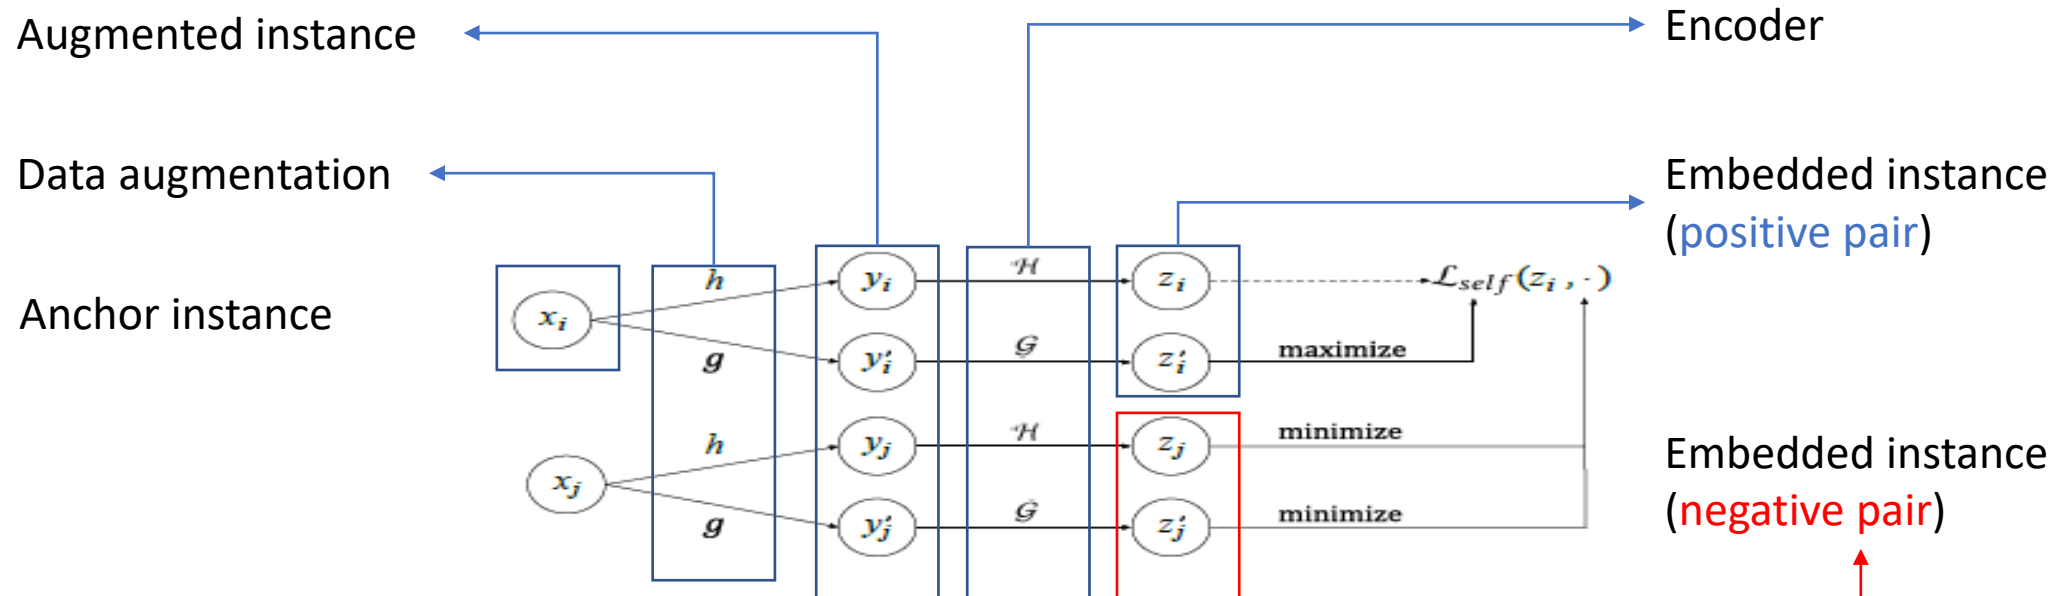


Figure 2: Self-supervised learning framework illustration. Two data augmentations h and g are applied to the input; Encoders \mathcal{H} and \mathcal{G} are applied to the augmented examples y_i and y'_i to generate embeddings z_i and z'_i . The SSL loss \mathcal{L}_{self} w.r.t. z_i is optimized towards maximizing the similarity with z'_i while minimizing the similarity between z_j and z'_j .

<그림> 대조 학습 방법론 프레임워크 (Yao et al., 2021)

Methodology

Methodology (Data)

- 본 연구에서는 대조 학습 기반 추천시스템의 학습을 위하여, UCSD에서 공개한 'RentTheRunway' 오픈 데이터 셋(Misra et al., 2018)을 활용함.
- RentTheRunway는 여성 의류 및 액세서리를 대여해주는 플랫폼으로써, 실제 사용자들의 제품 이용 기록, 평가 정보 및 사용자의 정보를 포함하고 있음.
- 해당 데이터 셋은 105,508명의 익명화 처리 된 유저 정보 및 5,850개의 제품에 대하여 192,544건의 트랜잭션 (transaction) 기록을 포함하고 있음.

Methodology (Data)

- Clothing Fit Dataset (RentTheRunway) (Misra et al., 2018)

Metadata

- ratings and reviews
- fit feedback (small/fit/large etc.)
- user/item measurements
- category information

Example (RentTheRunway)

```
{
  "fit": "fit",
  "user_id": "420272",
  "bust_size": "34d",
  "item_id": "2260466",
  "weight": "137lbs",
  "rating": "10",
  "rented_for": "vacation",
  "review_text": "An adorable romper! Belt and zipper were a little
hard to navigate in a full day of wear/bathroom use, but that's to be
expected. Wish it had pockets, but other than that-- absolutely
perfect! I got a million compliments.",
  "body_type": "hourglass",
  "review_summary": "So many compliments!",
  "category": "romper",
  "height": "5' 8\"",
  "size": 14,
  "age": "28",
  "review_date": "April 20, 2016"
}
```

- ✓ User data
 - User ID, Height, Weight, Age, Body type
- ✓ Item data
 - Item ID, Size, Category
- ✓ Transaction data
 - Fit, Rating, Renting purpose, Review(Full sentence, Summary)

<그림> RentTheRunway 데이터 예시

Methodology (Data)

- 데이터 전처리는 다음과 같이 실시함.

데이터 전처리	세부 사항	비고
데이터 제거	이용한 제품의 개수가 5개 미만인 사용자를 분석 대상에서 제거	평점 예측 결과 검증의 신뢰성을 위하여, Guo et al., (2022)의 방법을 이용함.
평점 스케일링	10점 척도를 5점 척도로 변환	2/4/6/8/10 점의 5개 평점만 존재하여 5점 척도 변환 수행

[표] 전처리 수행 세부 사항

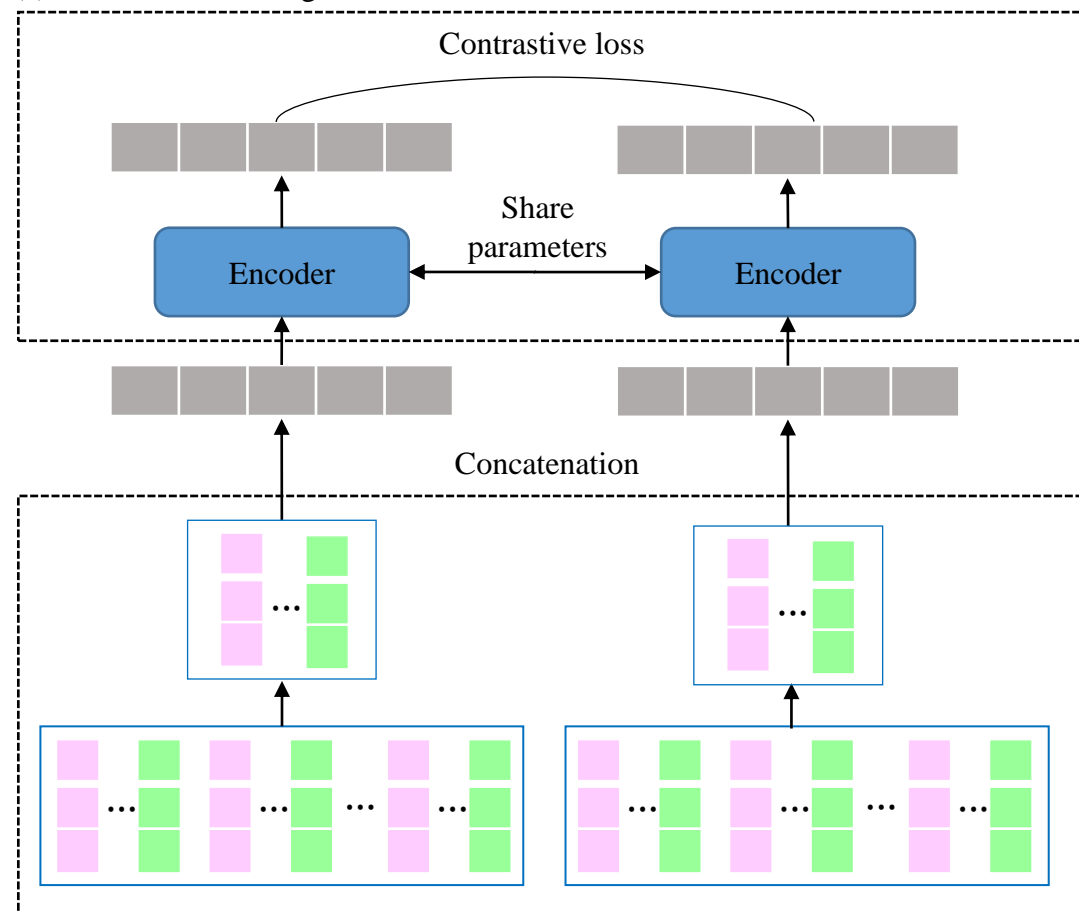
# of item	# of user	# of transaction	Avg. count (Transaction)	Sparsity
5,510	5,680	50,884	8.95	99.83%

[표] 분석 대상 데이터 통계 정보


Methodology(Overall framework)

- 본 연구에서는, 대조 학습과 추천시스템 총 두 단계를 통해, 전체 프레임워크의 학습을 진행함.
 - ✓ 대조 학습 단계(Contrastive learning task, CL task)
 - 데이터 증강 기법을 바탕으로, 특정 사용자가 이용한 제품 집합(item set)에 대해 multi-view(두 개 이상의 제품 집합)를 생성하고, 대조 학습 방법론을 인코더(Encoder) 모델에 적용
 - ✓ 추천시스템 단계 (Recommendation task)
 - 특정 사용자가 타겟 제품에 대하여 평점을 어떻게 매길 것인지를 예측
 - 입력 값을 선행 학습 단계에서 사용한 인코더 모델을 통과하여, 임베딩 벡터를 추출
 - 추출한 임베딩 벡터를 프로젝션 헤드(Projection head)에 통과시켜 타겟 제품에 대한 사용자의 평점 값을 예측
 - 학습 단계에서는, 실제 평점 값과 예측 평점 값의 차이를 손실 함수 값으로 설정하여, 프로젝션 헤드의 가중치를 업데이트(Transfer learning)


(c) Contrastive learning



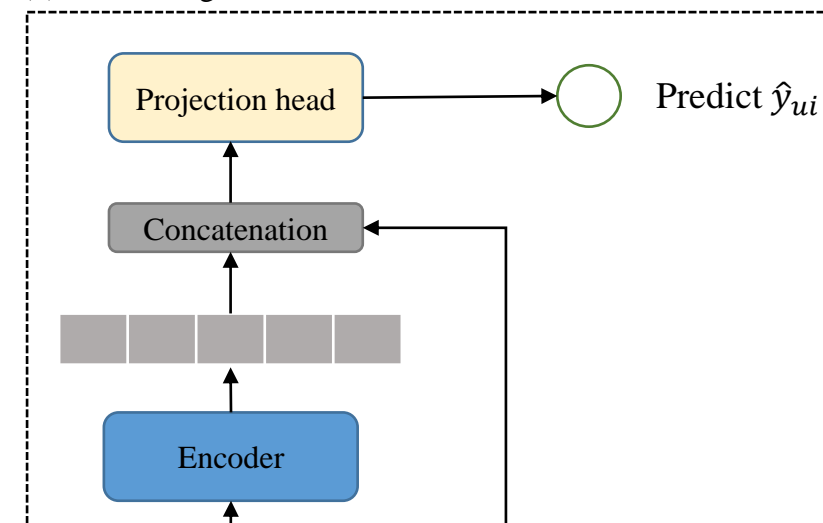
(b) Embedding & Pooling



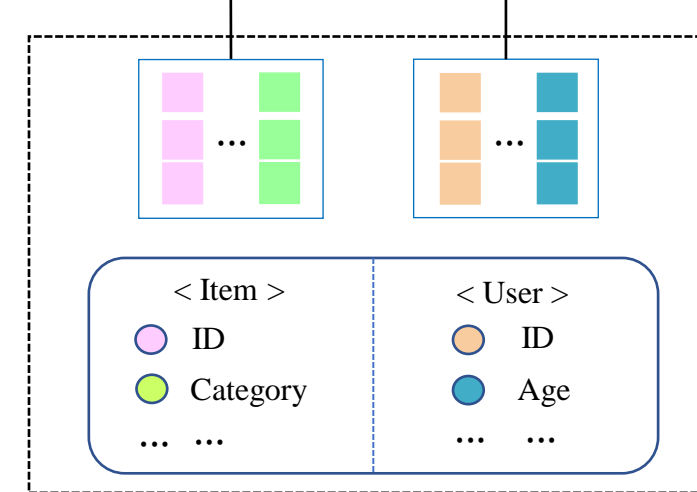
(a) Item substitution




(b) Fine-tuning



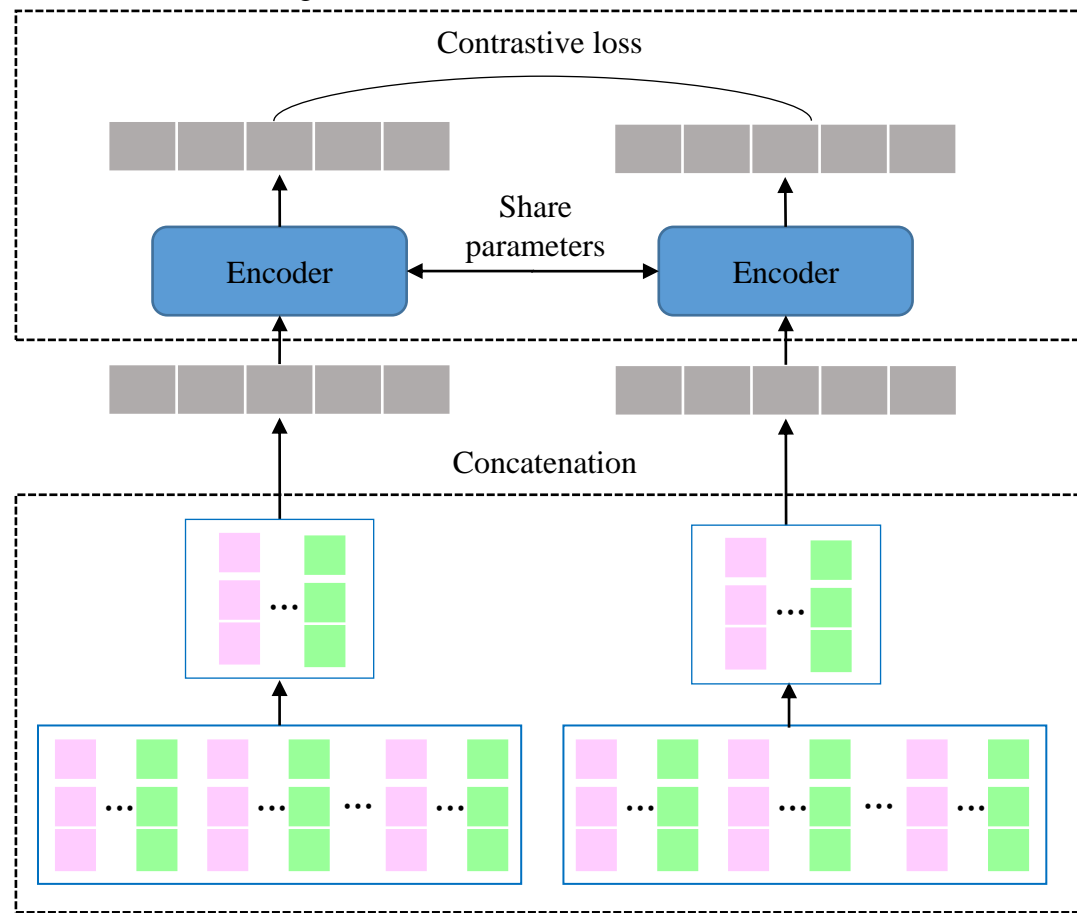
(a) Embedding




(a) Embedding



(c) Contrastive learning




(b) Embedding & Pooling



(a) Item substitution

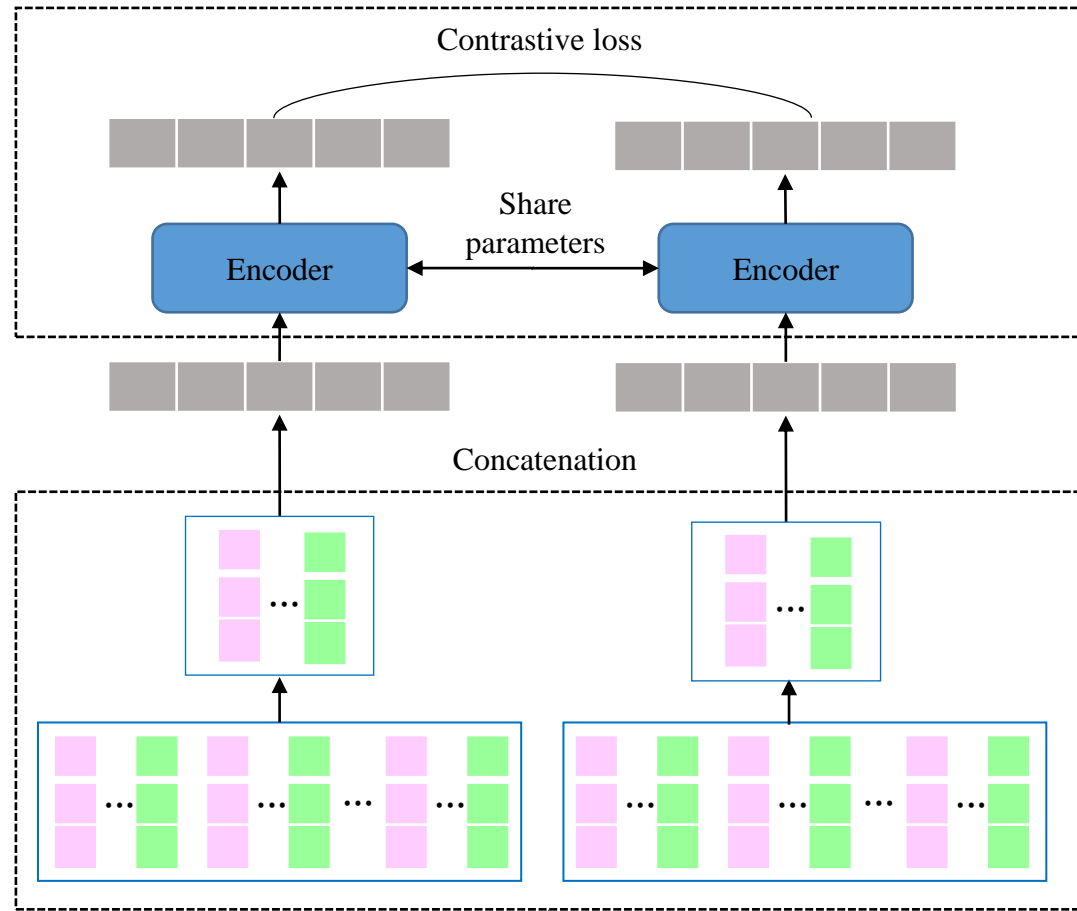
User's item set



① 데이터 증강 (Data Augmentation)

- 대조 학습을 추천 시스템에 적용한 선행 연구는 데이터 증강 방법으로서, 아이템 마스킹(Item masking) 또는 아이템 크롭핑(Item cropping)을 주로 사용하였음.
- 하지만, 임의적으로 제품을 마스킹하거나 크롭핑하는 경우, **제품 이용 기록이 거의 없는 사용자**에 대하여 **데이터 희소성 문제를 악화**시킬 수 있음 (Liu et al., 2021).
- 따라서, 본 연구에서는 **제품 평점 벡터**를 기반으로, **제품을 대체하는(substitute)** 방법을 이용함.
- 전체 제품 집합 중 α 의 비율만큼 제품이 대체되며 ($0 < \alpha \leq 1$), 이 때 평점 벡터 기반 **유사도 점수가 가장 높은 제품**을 선택함.

(c) Contrastive learning



(b) Embedding & Pooling

(a) Item substitution

① 데이터 증강 (Data Augmentation)

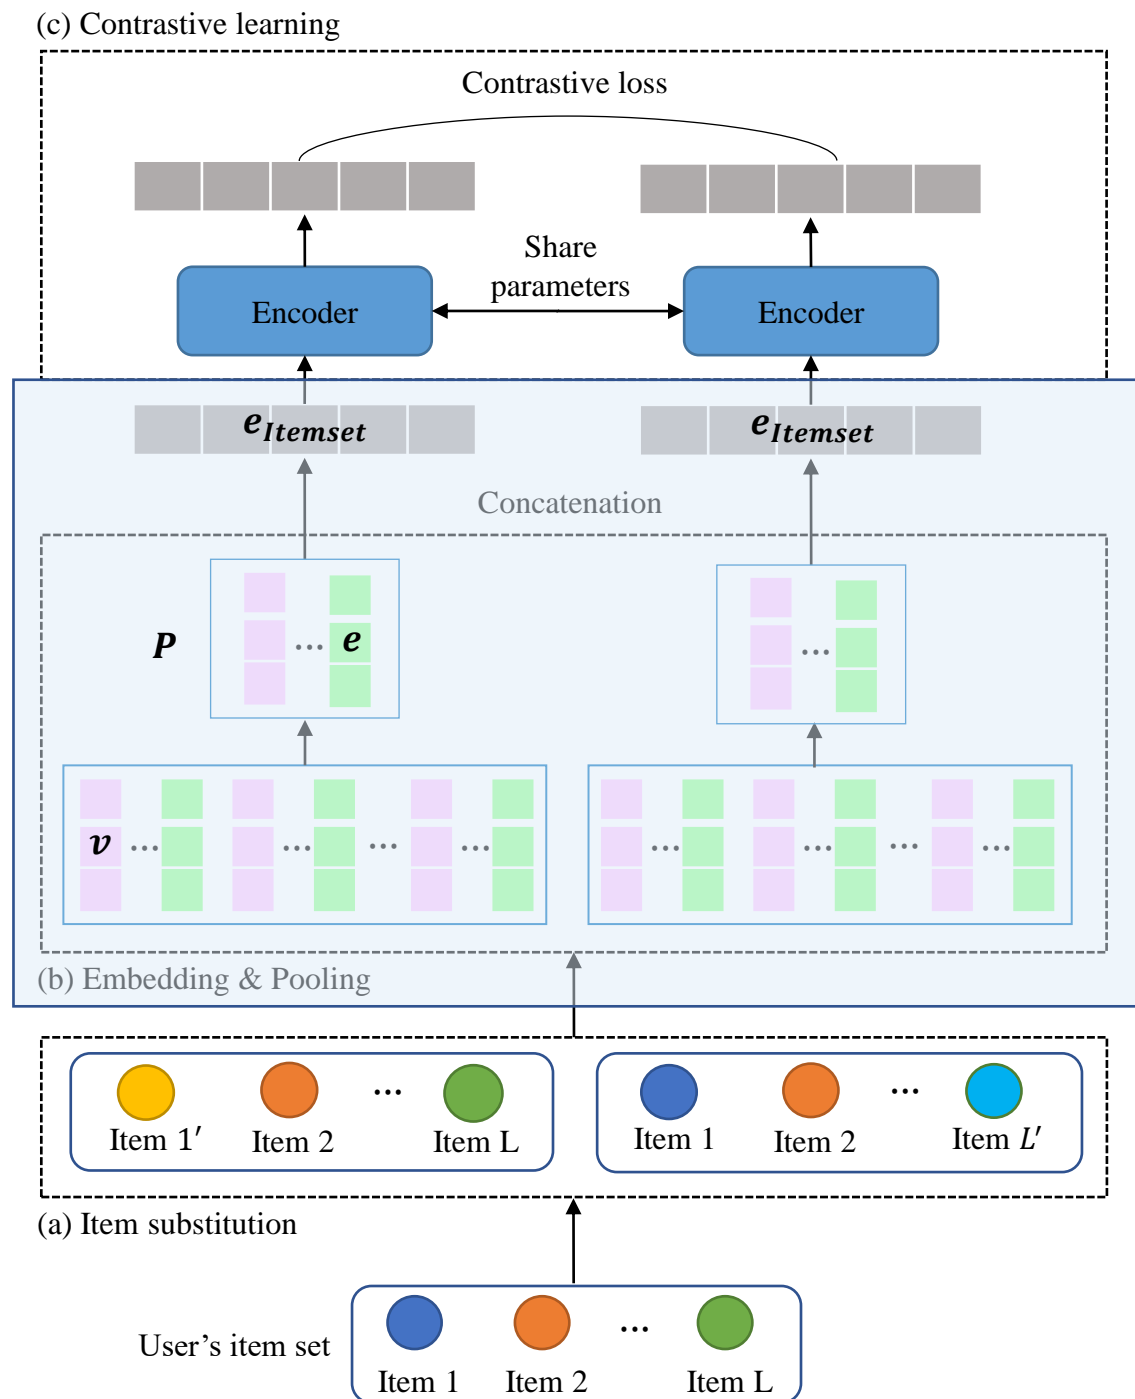
- 제품 대체의 기준이 되는 유사도를 본 연구에서는 **ISim(Inverse Similarity score)**로 정의하였고, 해당 수식은 아래와 같음.

$$\text{ISim}(i, j) = \frac{1}{\sqrt{|N(i)||N(j)|}} \times \frac{r_i^U \cdot r_j^U}{\|r_i^U\| \|r_j^U\|}$$

$$U = \{u \mid u \in S(i) \cap S(j)\}$$

- $|N(i)|, |N(j)|$ 는 각각 제품 i 와 j 를 이용한 사용자의 수, r_i, r_j 는 사용자 i 와 j 에 대한 평점 벡터를 의미
- U 는 제품 i 와 j 를 모두 이용한 사용자 집합
- 많은 사용자들이 이용한 제품일수록, 유사도를 계산에 끼치는 **영향력을 감소** (Breese et al., 2013)

- 이를 통해, 원본 제품 집합으로부터, **두 개의 증강된 제품 집합을 생성함.**
- 제품 대체 기반 방법은, 기존 cropping, masking 방식과 달리, **특정 사용자가 이용한 모든 제품의 정보를 사용함.**



② 특성 임베딩(Feature Embedding) & 풀링(Pooling)

- 데이터 증강이 완료된 각 제품에 대하여, 각 특성 별로 임베딩 층을 통과시켜 벡터를 생성함.
- 이 때, **사용자마다 이용한 제품의 개수가 다르므로**, 이를 처리해주는 과정이 필요함.
- 본 연구에서는 사용자가 이용한 모든 제품에 대하여, 제품의 특성을 표현하는 **임베딩 벡터를 풀링(mean pooling)**함.
- 결과적으로, 제품의 특성 개수와 일치하는 pooled embedding vector P 가 생성이 됨.

$$P = [e_1, \dots, e_{2k}]$$

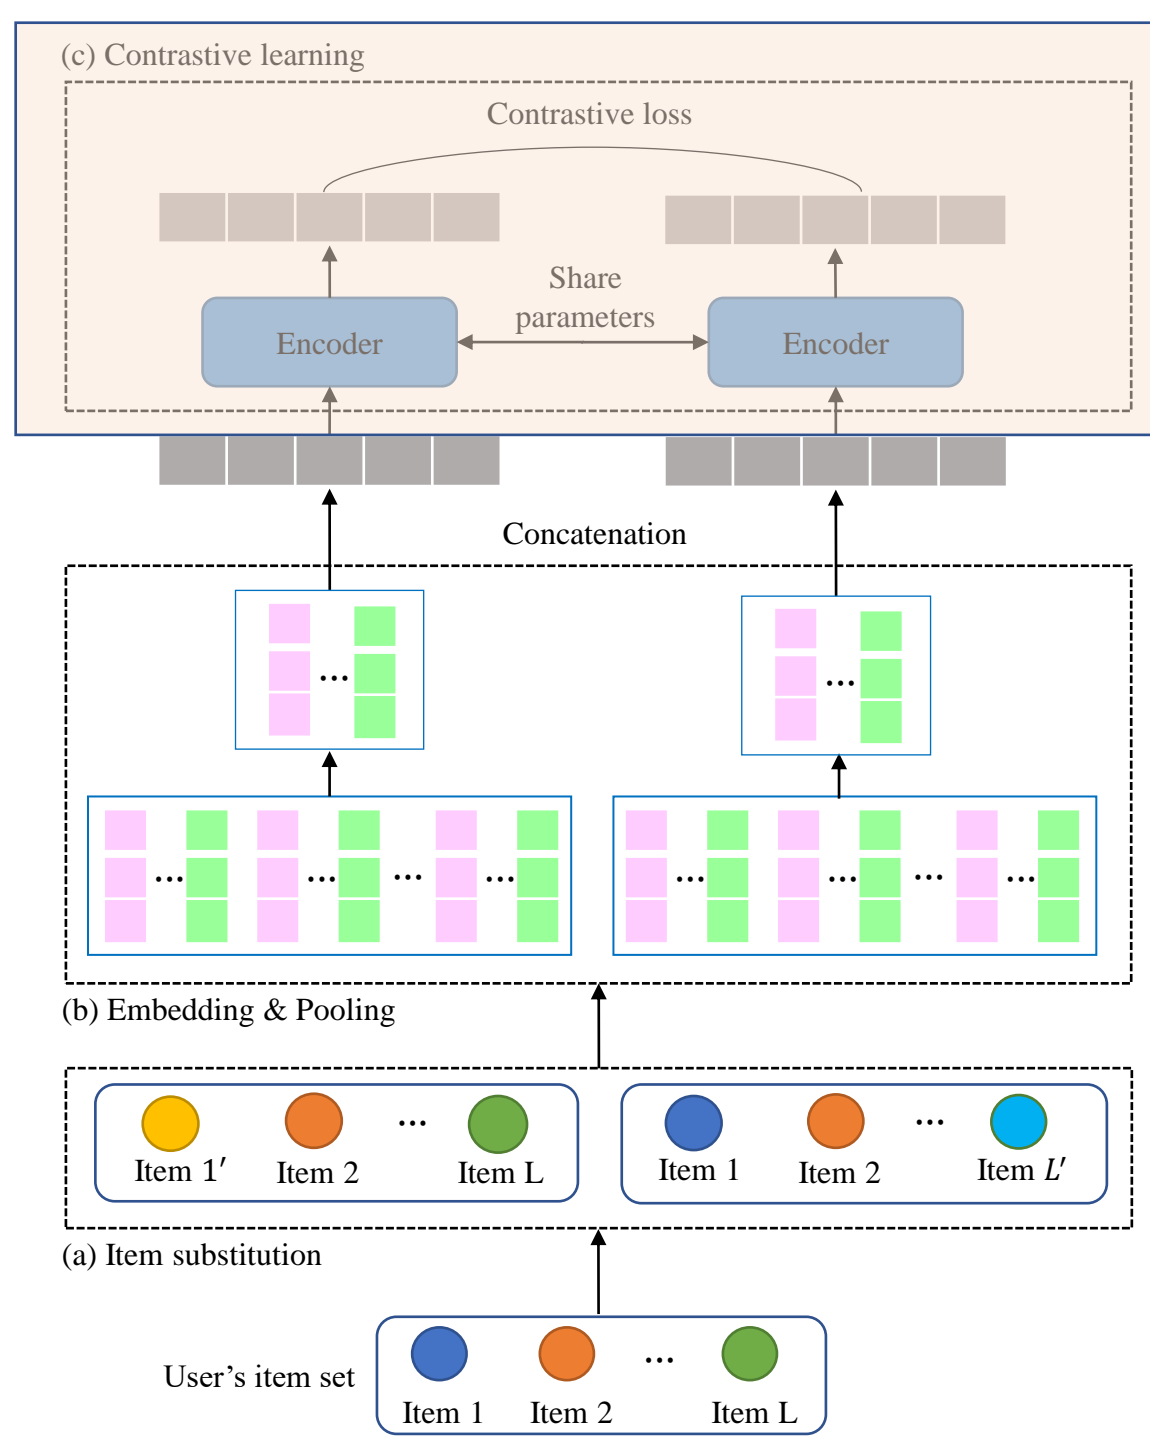
$$e_m = \frac{1}{L} \sum_{l=1}^L v_{lm} \quad (1 \leq m \leq k, 1 \leq l \leq L)$$

$$e_{Itemset} = e_1 || \dots || e_k \quad (e_{Itemset} \in \mathbb{R}^{d \times k})$$

- L 은 특정 사용자가 사용한 제품 갯수, k 는 제품 특성의 갯수, $e \in \mathbb{R}^d$ 는 제품 특성 한 개에 대한 임베딩 벡터, $||$ 는 결합 함수, $v_{lm} \in \mathbb{R}^d$ 는 l 번째 제품의 m 번째 특성에 대한 임베딩 벡터를 의미함.

③ 대조 학습 (Contrastive learning) 수행

- 특정 사용자가 이용한 제품들의 정보 벡터를 연결하고 (concatenate), 이를 대조 학습을 위한 인코더(Encoder)에 입력함.
- 두 개의 증강된 제품 집합을 각각 인코더 모델에 통과시켜 얻은 벡터에 대하여, 아래와 같이 대조 학습을 수행함.
 - ✓ 같은 제품 집합에서 증강된 제품 집합 간에는 유사도를 최대화
 - ✓ 서로 다른 제품 집합에서 증강된 제품 집합 간에는 유사도를 최소화
- 제품 대체 기반 대조 학습 방식은, 기존 Item cropping / masking 방식에 비해, 아래와 같은 이점이 있음.
 - ✓ 제품 집합 간의 유사성을 학습할 때, 더 많은 제품 정보를 학습
 - ✓ 따라서, 제품 간의 복합적인 관계를 효과적으로 학습



Methodology(CL task)

① 대조 학습 (실험 환경)

- 실험 환경
 - ✓ Tensorflow 2.10.0 / Python 3.9.3 / Weight & Biases 0.13.10
 - ✓ NVIDIA GeForce RTX 3060 12GB
 - ✓ Visual Studio code 1.75.1
- 데이터 분할
 - ✓ User ID를 기준으로 train / validation / test 데이터 셋을 7:1:2의 비율로 분할함.
 - ✓ 이 때, 이용한 제품의 개수를 바탕으로 층화 추출(Stratified sampling)을 수행함.
 - 상대적으로 transaction 데이터가 많거나(rich), 부족한(sparse) 사용자의 정보를 골고루 학습하고 평가하는 것을 목표로 함.

Methodology(CL task)

① 대조 학습 (손실 함수 정의)

- RentTheRunway 오픈 데이터 셋에 대하여 대조 학습을 수행함.
- 대조 학습에 사용할 손실 함수로서, Chen et al. (2020)이 제안한 [NT-Xent loss](#)를 선택함.

$$✓ \quad \ell(i, j) = -\log \frac{\exp(s(z_i, z_j)/\tau)}{\sum_{k=1}^{2N} \mathbb{I}_{[k \neq i]} \exp(s(z_i, z_k)/\tau)}$$

$$✓ \quad s(z_i, z_j) = \frac{z_i \cdot z_j}{\|z_i\| \|z_j\|}$$

$$✓ \quad \mathcal{L} = \frac{1}{2N} \sum_{k=1}^N [\ell(2k-1, 2k) + \ell(2k, 2k-1)]$$

- 또한, Sedhain et al. (2015)을 참고하여, 학습 과정 중 **과적합 현상(Overfitting)**을 방지하기 위하여 오토인코더에 대한 정규화 항을 추가함으로써, 아래와 같이 최종 손실 함수를 정의함 .

$$✓ \quad L_{Total} = L_{Self} + \lambda L_{AutoEnc} \text{ (Auto encoder Loss)}$$


$$✓ \quad L_{AutoEnc} = \|P(\tilde{x}_i) - A(P(\tilde{x}_i))\|_2^2 + \|P(\tilde{x}_j) - A(P(\tilde{x}_j))\|_2^2$$

Methodology(CL task)

① 대조 학습 (최적화 방식 및 평가 지표)

- 대조 학습의 평가를 위하여 지표로서, Categorical cross entropy를 사용함.
 - ✓ 하나의 제품 집합에 대하여, 자기 자신을 제외한 $(2N - 1)$ 개의 augmented pair 중에서 어떤 pair가 positive pair일지 예측하는 문제
 - ✓ 본 연구에서 positive pair는 동일한 제품 집합으로부터 증강된 아이템 집합 쌍을 의미함.
- 대조 학습 손실 함수에 대한 최적화를 위하여 Adam optimizer(Kingma & Ba, 2014)를 사용함.
- 또한, 학습 시작 단계에서 최적화와 관련하여, 너무 큰 학습율을 사용하는 것이 모델 학습의 불안정성을 야기할 가능성이 있음 (Goyal et al., 2017 He et al., 2019)
 - ✓ Goyal et al. (2017)을 참고하여 Learning rate warmup 기법을 사용함.
 - ✓ 초기 설정 학습율을 η 라 할 때, 현재 i 번째 step에 대한 학습율을 $\eta i / \omega$ 로 설정함.
 - ✓ Warmup step ω 이후로는, 학습율은 η


Methodology(CL task)



Methodology(CL task)

① 대조 학습 (인코더 모듈)

- Stacked Auto Encoder 모듈을 구현함.
- 총 4개의 Dense layer로 구성이 되어있으며, 모델 학습의 안정화를 위하여 배치 정규화(Ioffe & Szegedy, 2015) 및 ReLU 활성화 함수(Nair, V., & Hinton, 2010) 를 사용함.



Methodology(CL task)

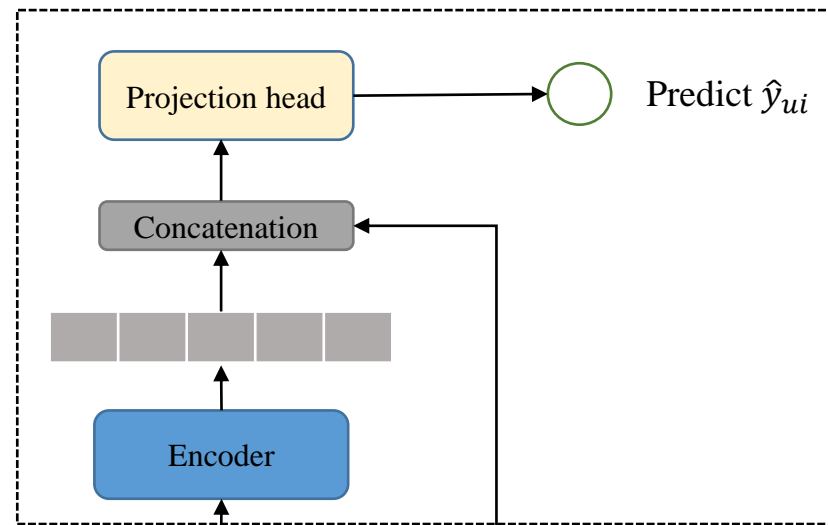
① 대조 학습 (하이퍼파라미터 튜닝)

- 대조 학습을 위하여 epoch 횟수는 250, Batch의 크기는 256, 개별 아이템 특성에 대한 임베딩의 차원은 64, 아이템 집합(시퀀스)의 최대 크기는 30, 초기 학습율은 0.001로 지정함.
- 추가적으로 하이퍼파라미터 튜닝을 실시하였으며, 대상 목록 및 탐색 범위는 아래 표와 같음.

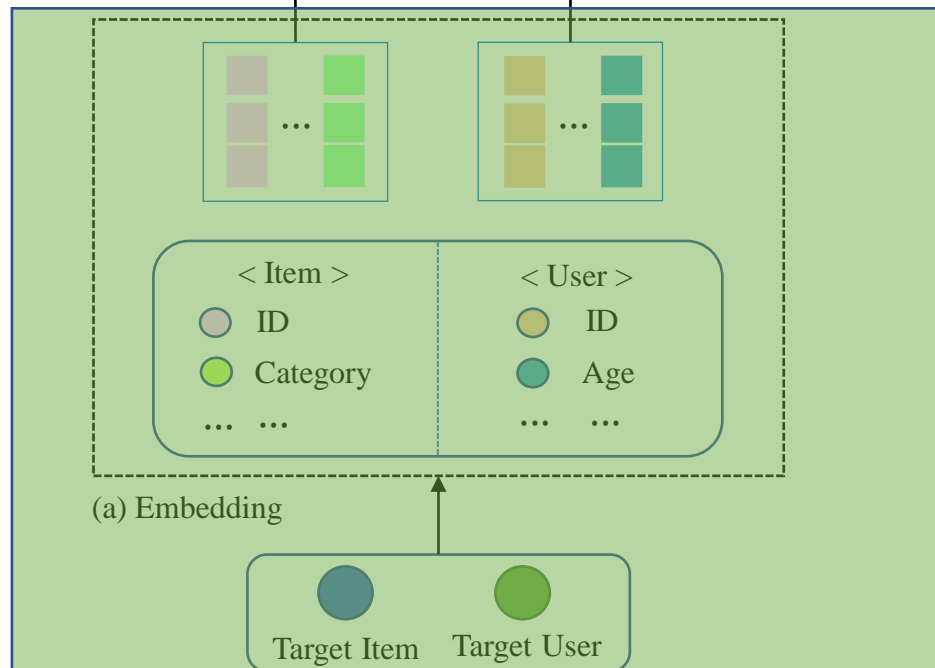
Character	Description	Search range
τ	Temperature parameter	{0.1, 1.0}
d	Ratio for Dropout	{0.1, 0.2, 0.3, 0.4, 0.5}
λ	Normalization parameter	{0.1, 0.2, 0.3, 0.4, 0.5}
γ	Ratio for data augmentation	{0.3, 0.4, 0.5, 0.6, 0.7}

[표] 대조 학습 하이퍼파라미터 튜닝 목록

(b) Fine-tuning

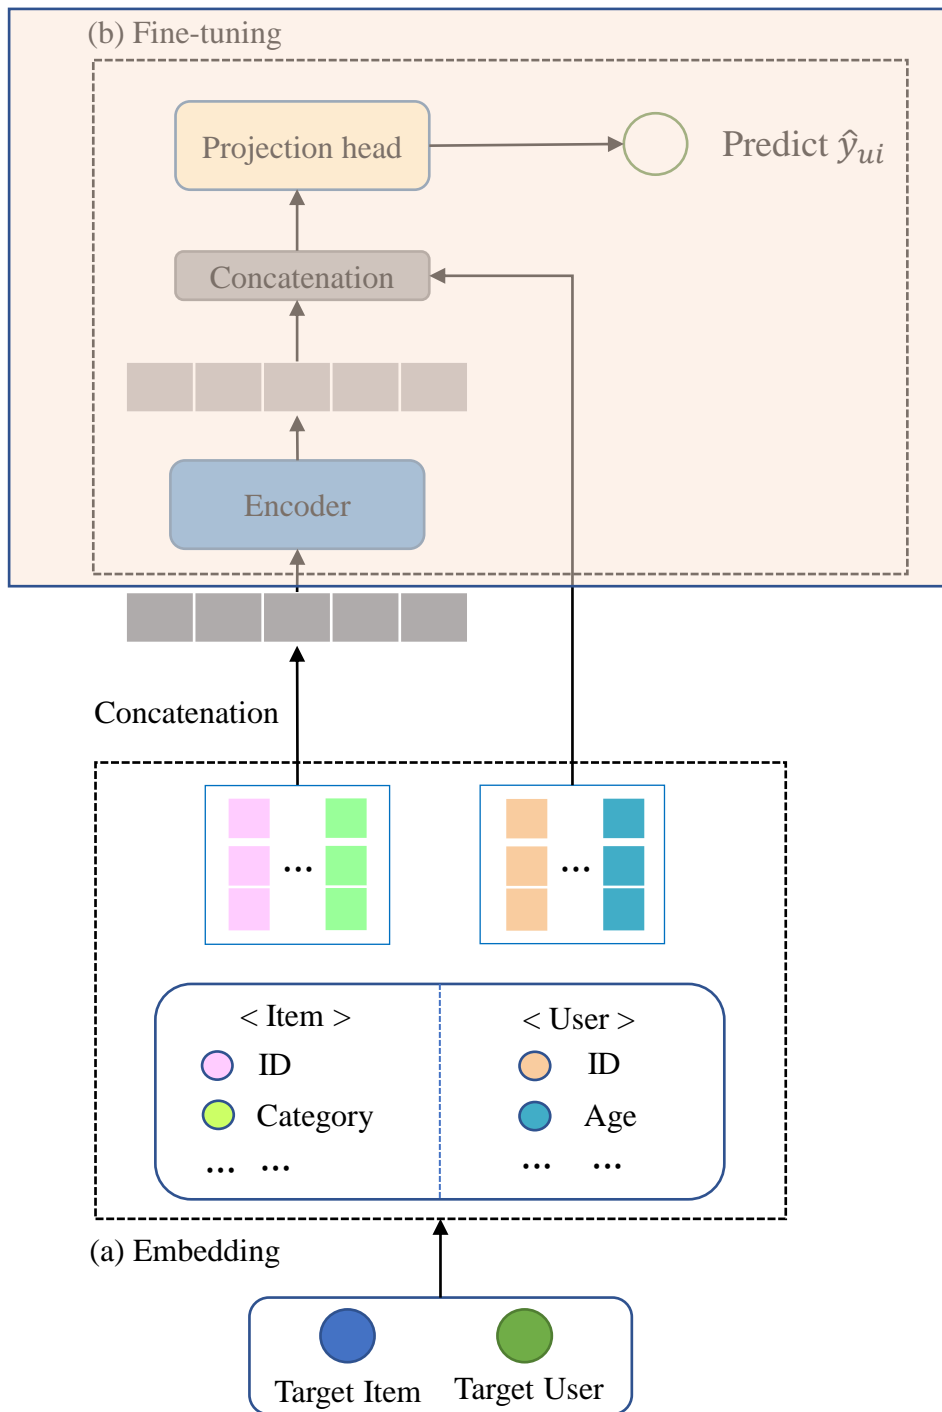


Concatenation



① 특성 임베딩(Feature Embedding)

- 추천시스템 단계에서는 특정 사용자가 타겟 제품에 대하여 평점을 얼마나 매길지 예측하는 방식으로 학습을 진행하고 평가함.
- 일차적으로, 타겟 제품 및 사용자의 각 특성에 대하여 임베딩 벡터를 생성함.
- 제품 특성 임베딩 벡터들을 하나의 단일 벡터로 결합하고, 이를 선행 학습 단계에서 학습시킨 오토인코더의 입력으로 함.
- 사용자 특성 임베딩 벡터의 경우, 하나의 단일 벡터로 결합하고, 이를 인코더 모델의 출력 값에 결합하여 프로젝션 헤드의 입력으로 함.



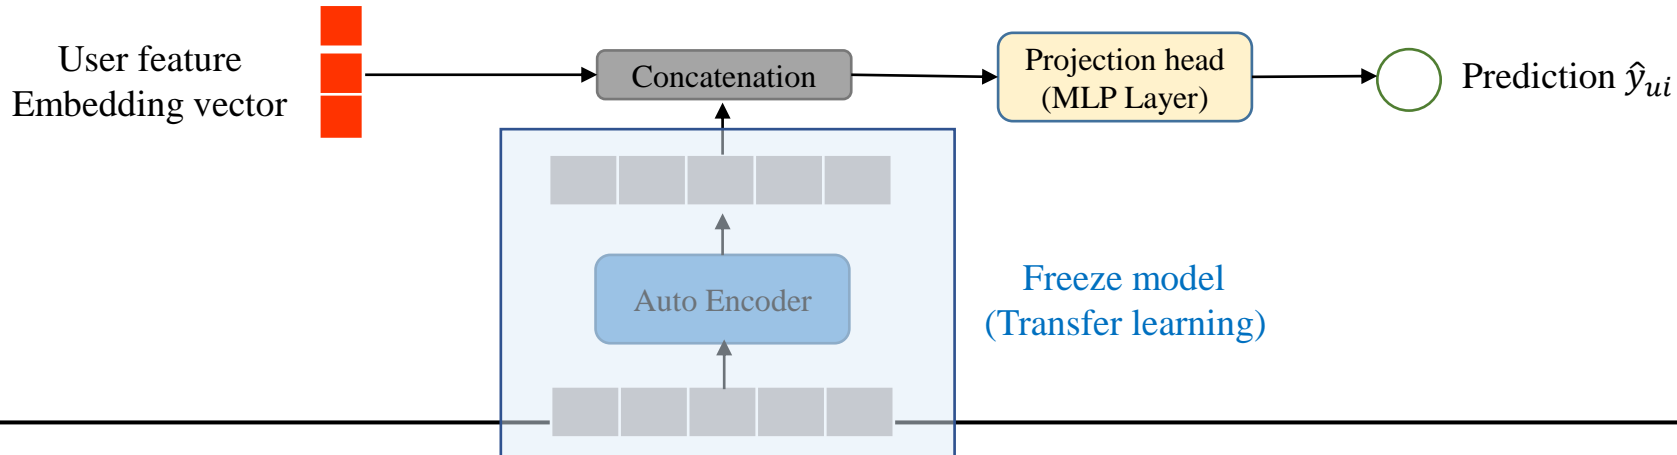
② 인코더를 통한 특징 추출 및 전이 학습 수행

- 선행 학습 단계에서 학습시킨 인코더 모델에, 제품 임베딩 벡터를 입력하여 특징 벡터를 추출함.
- 이 때, 인코더 모델에서 추출한 특징 벡터에, **사용자의 고유 정보(성별, 연령, 지역 정보 등)**를 임베딩한 벡터를 연결함.
- 연결된 벡터를 프로젝션 헤드(Projection head, 본 연구에서는 MLP Layer)의 입력으로 함.
- 프로젝션 헤드에서는 사용자의 정보도 반영이 된 벡터를 입력으로 받아 타겟 제품에 대한 평점을 예측함.
- 학습 단계에서는, 실제 평점 값과 예측 평점 값의 차이를 손실 함수 값으로 하여 **프로젝션 헤드 및 사용자 특성을 표현하는 임베딩 층(layer)의 가중치를 업데이트함.**
- 테스트 단계에서는, 모든 제품에 대하여 사용자의 평점 예측 값을 구하여, **평점이 높은 상위 K개의 제품을 유저에게 추천함.**

Methodology(Recommendation task)

② 추천시스템 프레임워크 (프로젝션 헤드 레이어)

- 사전 학습이 완료된 대조 학습 모델을 가져온 후, 프로젝션 헤드 레이어를 추가로 배치함으로써, 특정 사용자가 타겟 제품에 대하여 평점을 예측한 후 이를 학습함.
- 이 때, 대조 학습 모델에 대한 가중치는 동결함 (Freezing).
- 본 연구에서는 프로젝트 헤드로서, MLP(Multi Layer Perceptron) 레이어를 사용하였음.
 - ✓ Chen et al. (2020)에 따르면, 사전 학습된 모델 위에 너무 많은 레이어를 쌓으면, 사전 학습된 지식 (Knowledge)이 지나치게 추상화(abstraction)가 될 가능성이 존재함.
 - ✓ 따라서, 본 연구에서는 해당 상황을 방지하기 위하여 2개의 hidden layer를 쌓아 MLP를 구성함.



Methodology(Recommendation task)

② 추천시스템 프레임워크 (손실 함수 정의 및 최적화)

- 추천시스템 학습에 사용할 손실 함수로서, Root Mean Squared Error(RMSE)를 사용함.
 - ✓ 모델 평가 지표(Metric)도 동일함.
- 추천시스템 모델의 손실 함수에 대한 최적화를 위하여 Adam optimizer을 사용함.
- 또한, 대조 학습 과정과 동일하게 모델 학습의 안정화를 위하여 Learning rate warmup 기법을 사용함.
 - ✓ 초기 설정 학습율을 η 라 할 때, 현재 i 번째 step에 대한 학습율을 $\eta i / \omega$ 로 설정함.
 - ✓ Warmup step ω 이후로는, 학습율은 η

Methodology(Recommendation task)

② 추천시스템 프레임워크 (하이퍼파라미터 튜닝)

- 추천시스템 프레임워크 학습을 위하여 epoch 횟수는 200, 개별 제품 특성을 표현하는 임베딩 벡터의 차원은 64로 지정함.
- Early stopping 방법을 통하여, 검증 데이터 셋에 대한 RMSE 값이 개선되지 않을 경우 학습을 중단함 (20 epochs).
- 이 때, 사전 학습 된 대조 학습 모델은 데이터 증강 방법 별로, 각각 [Categorical cross entropy 값이 가장 낮은 모델](#)을 가져와 [전이 학습\(Transfer learning\)](#)을 수행함.
- 추가적으로 하이퍼파라미터 튜닝을 실시하였으며, 대상 목록 및 탐색 범위는 아래 표와 같음.

Character	Description	Search range
N	Batch size	{ 128, 256, 512 }
d	Ratio for Dropout	{ 0.1, 0.2, 0.3, 0.4, 0.5 }
η	Learning rate	{ 1e-4, 1e-3, 1e-2 }

[표] 추천시스템 프레임워크 학습 하이퍼파라미터 튜닝 목록

Experiment

Experiment

- 본 연구에서 제시한 프레임워크의 효과를 확인하기 위하여, 아래 네 가지 요소에 대한 분석을 실시함.
 - ✓ **Diversity analysis (다양성 분석, RQ1)**: 본 연구에서 제시한 프레임워크를 적용하였을 때, baseline 모델에 비하여, 추천시스템 다양성이 얼마만큼 향상이 되었는가?
 - ✓ **Data sparsity analysis (데이터 희소성 분석, RQ2)**: 본 연구에서 제시한 프레임워크를 적용하였을 때, 사용자의 상호작용(interaction) 데이터가 부족한 상황에서, baseline 모델에 비하여 추천시스템 다양성이 어느정도 개선이 되었는가?
 - ✓ **Framework component analysis (프레임워크 구성요소의 효과 분석, RQ3)**: 본 연구에서 제안한 프레임워크의 구성 요소가 실제로 추천시스템 다양성에 얼마만큼 영향을 끼치는가?
 - ✓ **Item embedding quality analysis (아이템 임베딩 질적 분석, RQ4)**: 본 연구에서 제안한 추천시스템 프레임워크가, 기존 데이터 증강 방법을 적용한 대조 학습 방법에 비하여 효과적으로 제품의 정보를 학습하였는가?
-

Experiment (RQ1)

① Diversity analysis (다양성 분석, RQ1)

- 본 연구에서 제시한 프레임워크를 적용하였을 때, baseline 모델 대비 [추천시스템 다양성의 개선 정도를 확인](#)함.
- 다양성 분석을 위한 baseline 모델로서 아래 세 가지를 사용함.
 - ✓ Neural Collaborative Filtering (NCF) (He et al., 2017)
 - ✓ Autoencoder with collaborative filtering (AutoRec) (Kuchaiev & Ginsburg, 2017; Sedhain et al., 2015)
 - ✓ Variational autoencoder with collaborative filtering (VAERec) (Liang et al., 2018; Shenbin et al., 2020)
- 본 연구에서 사용한 추천시스템 다양성 지표는 아래와 같음.
 - ✓ [Long-tail Prediction Coverage \(LPC\)](#)
 - ✓ [Average Percentage of Long Tail Items \(APLT\)](#)

LPC

- Long-tail Prediction Coverage (LPC) (Ge et al., 2010) : 추천시스템이 전체 사용자에게 추천한 제품 개수 대비, 추천을 받은 롱테일 제품의 비율을 나타내는 지표임.

$$\text{Long - tail Prediction Coverage (LPC)} = \frac{|I_{p-long}|}{|I_p|}$$

$|I_p|$: the size for the set of items for which a prediction can be made

$|I_{p-long}|$: the size for the set of long - tail items for which a prediction can be made

- 0 ~ 1 사이의 값을 가지며, 값이 높을 수록 추천 시스템이 롱테일 제품을 다양하게 추천해준다는 것을 의미함.
- 거시적 관점 (LPC): 사용자 집단에 제품을 추천하였을 때, 롱테일에 속한 제품의 개수가 많음을 의미함.

APLT

- Average Percentage of Long Tail items (APLT) (Abdollahpouri et al., 2019): 해당 지표는 개별 사용자에게 평균적으로 어느 정도의 비율 만큼 롱테일에 속한 제품을 추천했는지 측정하는 지표임.

$$APLT = \frac{1}{|U_t|} \sum_{u \in U_t} \frac{|\{i, i \in (L_u \cap \Gamma)\}|}{|L_u|}$$

$|U_t|$: the number of users in the test set

L_u : the recommended list of items for user u

Γ : the set for long tail item

- LPC와 동일하게 0 ~ 1 사이의 값을 가지며, 값이 높을 수록 추천 시스템이 롱테일 제품을 다양하게 추천해준다는 것을 의미함.
- 미시적 관점 (APLT): 특정 사용자에게 추천해준 제품(들)이 롱테일에 속할 확률이 높음을 의미함.

Experiment (RQ1)

① Diversity analysis (다양성 분석, RQ1)

- 본격적인 분석에 앞서, ISCLRec 모델 및 baseline 모델에 대하여, 테스트 데이터를 대상으로 모델의 예측 정확도를 평가하였음. -> Root Mean Square Error(RMSE), Mean Absolute Error(MAE)
- 모델 별 추천시스템 모델의 예측 정확도는 아래 표와 같음.
 - ✓ **RMSE 지표**: 본 연구에서 제안한 ISCLRec 모델의 성능이 가장 높은 것을 확인함.
 - ✓ **MAE 지표**: VAERec 모델의 성능이 가장 높은 것을 확인하였으며, RMSE 값과 MAE 값의 차이가 가장 심한 것을 확인함. -> 이상치에 영향을 많이 받은 모델임을 확인할 수 있음.

Metrics	Model			
	NCF	AutoRec	VAERec	ISCLRec (Ours)
RMSE	0.786	0.805	1.043	0.754
MAE	0.588	0.664	0.144	0.601

[표] 모델 별 예측 정확도

Experiment (RQ1)

① Diversity analysis (다양성 분석, RQ1)

- 다양성 측정을 위해, 각 사용자 별로 **네거티브 샘플(negative sample)**을 선정함.
 - ✓ **네거티브 샘플** : 사용자와의 상호작용(평점) 기록이 없는 모든 제품
- 각 사용자 별로, 네거티브 샘플에 대한 평점을 예측하고, 평점 기준 상위 K개의 제품을 추천함.
 - ✓ K = 10, 15, 20
- K 값에 따른 다양성 지표를 측정하였으며, 결과는 아래 표와 같음.

Model	K = 10		K = 15		K = 20		Improvement (%)	
	LPC	APLT	LPC	APLT	LPC	APLT	LPC	APLT
NCF	0.601	0.480	0.613	0.489	0.620	0.498	39.3	88.1
AutoRec	0.640	0.680	0.647	0.672	0.646	0.667	32.1	36.6
VAERec	0.706	0.700	0.705	0.711	0.702	0.719	20.8	29.6
ISCLRec(Ours)	0.917	0.942	0.840	0.916	0.797	0.901	-	-

[표] 프레임워크 구성요소 별 다양성 지표

Experiment (RQ2)

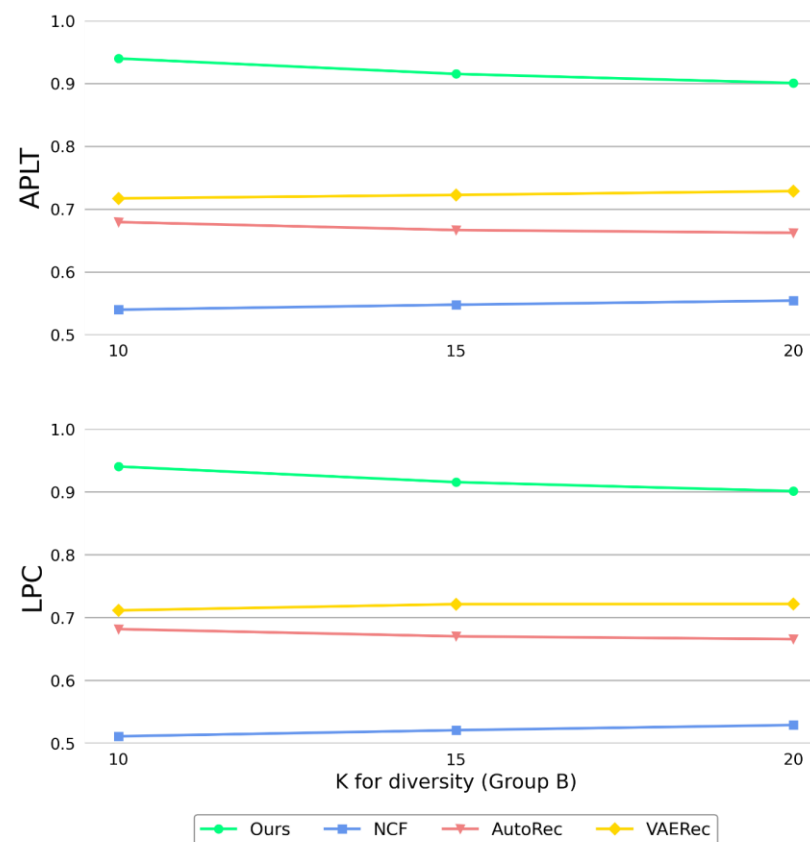

② Data sparsity analysis (데이터 희소성 분석, RQ2)

- 사용자와 아이템 간 상호작용(interaction) 데이터가 부족한 상황에서도, 본 논문에서 제안한 추천시스템 프레임워크가 baseline model에 비하여 얼마나 다양하게 제품을 추천해줄 수 있는지 확인함.
- 분석 대상 사용자는 다음과 같이 제품 이용 횟수를 기준으로 선택함.
 - ✓ 전체 제품 목록 중에서, 상호작용(제품 구매, 제품 클릭, 평점, 리뷰 등) 기록이 있는 제품의 개수가 특정 값 미만인 사용자를 선택함.
 - 테스트 셋에 속한 사용자 중, 제품 이용 횟수 기준 하위 10%에 속하는 사용자 집단 (GROUP A)
 - 테스트 셋에 속한 사용자 중, 제품 이용 횟수 기준 평균 50%에 속하는 사용자 집단 (GROUP B)
- RQ1과 동일하게 각 유저 별로, 네거티브 샘플에 대한 평점을 예측하고, 평점 기준 상위 K개의 제품을 추천함.
 - ✓ $K = 10, 15, 20$

Experiment (RQ2)

② Data sparsity analysis (데이터 희소성 분석, RQ2)

- K값에 따른 APLT 및 LPC line plot은 아래 그림과 같음.



Experiment (RQ2)

② Data sparsity analysis (데이터 희소성 분석, RQ2)

- Group A와 Group B 모두 본 연구에서 제안한 프레임워크(ISCLRec)가 baseline model에 비하여, LPC 및 APLT 값이 높은 것을 확인함.
 - ✓ 거시적 관점 (LPC): 사용자 집단에 제품을 추천해줬을 때, 롱테일에 속한 제품의 개수가 많음.
 - ✓ 미시적 관점 (APLT): 특정 사용자에게 추천해준 제품이 롱테일에 속할 확률이 높음.

Experiment (RQ3)

③ Framework component analysis (프레임워크 구성요소의 효과 분석, RQ3)

- 본 연구에서 제안한 프레임워크를 **ISCLRec** (Item Substitution Contrastive Learning Recommendation)으로 정의하였으며, 각 구성 요소가 실제로 추천시스템 다양성에 얼마나 영향을 미치는지 확인하고자 함.
- ISCLRec 프레임워크와, 프레임워크의 구성 요소(component)를 대체 또는 제거한 모델의 다양성 지표를 비교함.
 - ① **ISCLRec** : Item substitution + Contrastive learning task + recommendation task
 - ② **RecIC** : Item cropping + Contrastive learning task + recommendation task
 - ③ **RecIM** : Item masking + Contrastive learning task + recommendation task
 - ④ **OnlyRec**: Recommendation task (without contrastive learning)
- 본 연구에서 사용한 다양성 지표는 아래와 같음.
 - ✓ **Long-tail Prediction Coverage (LPC)**
 - ✓ **Average Percentage of Long Tail Items (APLT)**

Experiment (RQ3)

③ Framework component analysis (프레임워크 구성요소의 효과 분석, RQ3)

- 본격적인 분석에 앞서, 앞서 나열한 네 가지 모델에 대하여, 테스트 데이터를 대상으로 모델의 예측 정확도를 평가하였음. -> Root Mean Square Error(RMSE), Mean Absolute Error(MAE)
- 프레임워크 구성요소 별 추천시스템 모델의 예측 정확도는 아래 표와 같음.
- 정확도 측면에서는, 대조 학습 프레임워크를 적용하지 않은 모델(OnlyRec)이 가장 뛰어난 것을 확인함.
 - ✓ **추천시스템 프레임워크**: 특정 사용자가 타겟 제품에 남긴 평점 정보를 학습 (**타겟 정보만 집중**)
 - ✓ **대조 학습 프레임워크**: 타겟 제품과 나머지 제품들 간의 **관계(유사성) 정보를 학습** -> 타겟 제품에 대한 평점을 타겟과 유사한 제품들의 평점을 반영하여 예측 -> 일종의 **노이즈(noise)**로 작용할 가능성이 존재

Metrics	Model			
	RecIC	RecIM	ISCLRec (Proposed)	OnlyRec
RMSE	0.758	0.768	0.755	0.734
MAE	0.615	0.630	0.601	0.560

[표] 프레임워크 구성요소 별 예측 정확도

Experiment (RQ3)

③ Framework component analysis (프레임워크 구성요소의 효과 분석, RQ3)

- 데이터 증강 방법 및 K(추천한 제품의 수) 값에 따른 다양성 지표를 측정하였으며, 결과는 아래 표와 같음.
- 본 연구에서 제안한 모델(ISCLRec)이 Item Cropping/Masking 기반 모델과 대조 학습(CL)을 제외한 모델보다 LPC, APLT 값이 높음을 확인함.
 - ✓ 제품을 대체하여 대조 학습을 적용할 경우, 기존 방식에 비하여 **제품 간의 관계를 보다 복합적으로 파악**할 수 있고, 이에 따라 추천시스템의 다양성을 향상시킨 것으로 판단함.

Model	K = 10		K = 15		K = 20		Improvement (%)	
	LPC	APLT	LPC	APLT	LPC	APLT	LPC	APLT
OnlyRec	0.429	0.126	0.593	0.289	0.634	0.400	60.4	330.0
RecIC	0.632	0.781	0.623	0.751	0.626	0.728	35.8	22.1
RecIM	0.662	0.766	0.634	0.740	0.638	0.719	32.0	24.0
ISCLRec (Proposed)	0.917	0.942	0.840	0.916	0.797	0.901	-	-

[표] 프레임워크 구성요소 별 다양성 지표


Experiment (RQ4)

④ Item embedding quality analysis (아이템 임베딩 질적 분석, RQ4)

- 본 연구에서 제안한 ISCLRec 프레임워크가, 기존 데이터 증강 방법(Item masking, Item cropping)을 적용한 대조 학습 방법에 비하여, 효과적으로 제품의 정보를 학습하는 지 확인함.
 - ✓ 제품에 대한 임베딩 행렬을 바탕으로, **헤드와 롱테일에 속한 제품 간의 평균 유사도를 계산**
- 아이템 임베딩 질적 분석을 위하여, 아래와 같은 절차를 수행함.
 - 1) 제품 이용 기록 횟수를 기준으로, 상위 3개의 제품 군을 선정
 - 2) 각 제품 군 별로, 헤드 및 롱테일에 속한 제품 목록을 추출
 - 3) 학습된 추천 시스템 모델의 제품 임베딩 행렬(matrix)을 추출
 - 4) 제품 임베딩 행렬을 이용하여, 각 제품 군에 소속된 아이템 쌍(pair)에 대하여 코사인 유사도를 계산
 - 5) 4)에서 얻은 제품 유사도 행렬에서, 헤드 제품에 속하는 행과 롱테일 제품에 속한 열을 추출
 - 6) 5)에서 얻은 제품 유사도 행렬에서, 모든 헤드 제품에 대하여 롱테일 제품 간 유사도의 평균을 계산

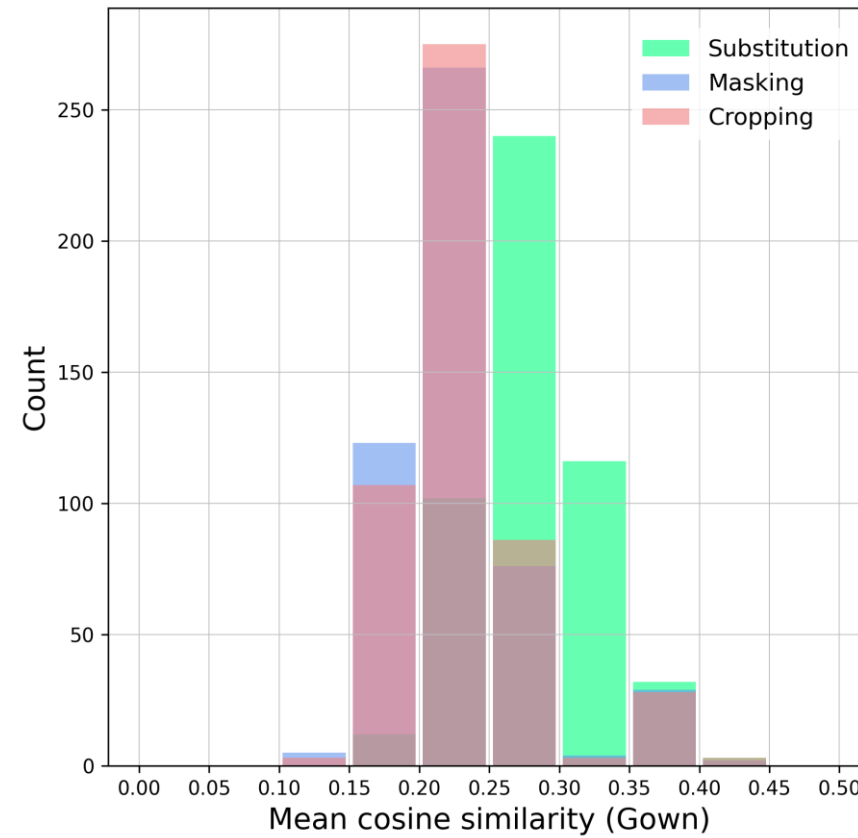
Experiment (RQ4)

- Dress 카테고리




Experiment (RQ4)

- Gown 카테고리



Experiment (RQ4)

- Sheath dress 카테고리



Experiment (RQ4)

Augmentation method	Category	Mean similarity (<i>Head</i> ↔ <i>Long</i> – <i>tail</i>)
Item masking	Dress	0.113
	Gown	0.230
	Sheath dress	0.180
Item cropping	Dress	0.112
	Gown	0.232
	Sheath dress	0.212
Item substitution (Proposed)	Dress	0.221
	Gown	0.281
	Sheath dress	0.267
<i>Improve_{mean}</i> (%)	Dress	96.5%
	Gown	21.6%
	Sheath dress	37.1%

[표] 데이터 증강 방법에 따른 제품 간 평균 유사도 비교

Experiment (RQ4)

④ Item embedding quality analysis (아이템 임베딩 질적 분석, RQ4)

- 분석 결과, 기존 Item masking / Item cropping 방식에 비하여, 유사도에 기반한 제품 대체 방법을 적용하였을 때, 헤드 제품과 롱테일 제품 간 평균 유사도 값이 가장 높은 것을 확인함.
 - ✓ Dress 제품 군: 평점 벡터 기반 제품 대체 방법이, 기존 방식에 비해 평균 유사도가 96.5% 향상
 - ✓ Gown 제품 군: 기존 방식에 비해 평균 유사도가 21.6% 향상
 - ✓ Sheath dress 제품 군: 기존 방식에 비해 평균 유사도가 37.1% 향상
- 헤드와 롱테일에 속한 제품 간의 유사도가 높을수록, 기존에 헤드 제품을 이용한 사용자에게 롱테일에 속한 제품을 추천해줄 확률이 높아지므로, 다양성이 (LPC, APLT 지표) 기존 방식에 비하여 향상된 것으로 판단함.

Implication

Implication

- 해당 연구를 통하여 이끌어낼 수 있는 학술적 시사점은 아래와 같음.

- ✓ **학술적 측면:**

1. 대조 학습 프레임워크에서 론텔일에 속하는 제품의 추천 빈도를 높이기 위하여, 사용자가 평가한 제품 평점 벡터를 바탕으로, 추천 후보 아이템과 가장 유사한 제품으로 대체하는 데이터 증강 기법을 제안함.
2. 제품 대체 기반 대조 학습 프레임워크를 통해 제품 간의 유사성을 학습함으로써, 추천 시스템 단계에서 사용자에게 제품을 추천할 때, 제품에 대한 인기도(Popularity)의 영향을 최대한 받지 않고, 보다 다양하게 제품을 추천할 수 있음.

Implication

- 해당 연구를 통하여 이끌어낼 수 있는 실무적 시사점은 아래와 같음.

- ✓ **실무적 측면:**

1. 본 연구에서 제안한 프레임워크는 도메인 어그노스틱(Domain-agnostic)하기 때문에, 연구 결과를 다양한 분야로 확장할 수 있음.
 - ✓ 예시) 식당의 가격, 위치 및 종류 등의 식당 정보와 특정 사용자가 이용한 식당 목록을 바탕으로, 사용자가 만족할 만한 식당을 추천해줄 수 있음.
2. 전자상거래 기업에서는 인기 제품과 특성이 유사하지만 현재까지 덜 주목받던 제품을 소비자에게 알릴 수 있는 기회가 증가하고, 이는 기업의 이윤 상승의 한 가지 방법이 될 수 있음. 한편, 소비자는 이제까지 경험해보지 못한 제품을 추천받을 수 있으며, 이에 따라 만족감이 증대될 수 있음.
3. 본 연구 결과를 활용하거나, 추가 연구를 수행하기 위하여 사용 가능한 장비 또는 금전적 상황에 따라서 프레임워크의 구성요소(인코더 모듈, 디코더 모듈)를 변경하기 용이함.

Limitations & Future work

Limitations & Future work

- 해당 연구의 한계점 및 이에 따른 향후 연구 계획은 다음과 같음.

① 시간 복잡도

- 본 연구에서 제안한 ISCLRec 프레임워크는, 타겟 사용자의 모든 네거티브 샘플에 대하여 평점을 예측한 후, 평점 기준 상위 K개의 제품을 추천해주는 방법을 사용함.
 - 따라서, 실제 전자 상거래 플랫폼에서 사용자에게 제품을 추천해줄 때, 플랫폼 상에 존재하는 모든 제품의 정보를 조회하여 순위를 매기는 것은 시간 복잡도(Time complexity)가 매우 높음.
- 향후 연구에서는, 네거티브 샘플 내에서 평점을 예측할 제품을 일차적으로 필터링한 후, 남은 제품들에 대해서 평점을 예측하는 방법에 대하여 연구할 예정임.
- 군집화(Clustering) 방법을 활용하여, 타겟 사용자가 사용한 제품과 동일한 군집에 소속된 제품을 대상으로 평점을 예측

Limitations & Future work

② 사용자 관점의 편향성(Bias)

- 본 연구에서 제안한 ISCLRec 프레임워크는 사용자 관점에서의 편향성(Bias)을 고려하지 못하였다는 한계점이 존재함.
 - 예를 들어, 연령대 및 거주지, 그리고 성별 등의 특성에 따라 사용자에게 추천하는 제품 군이 편중될 가능성이 존재하는데, 본 연구에서는 해당 사항을 고려하지 못함.
- 향후 연구에서는, 사용자의 연령, 성별, 거주지 등의 사용자 컨텍스트(Context)를 다각도로 분석하여 사용자의 편향성을 최대한 낮춤으로써, 추천 시스템의 다양성을 향상시킬 수 있는 방법을 연구하고자 함.

Thank you for listening!

Reference

- Abdollahpouri, H., Burke, R., & Mobasher, B. (2019). Managing popularity bias in recommender systems with personalized re-ranking. *arXiv preprint arXiv:1901.07555*.
- Bian, S., Zhao, W. X., Zhou, K., Cai, J., He, Y., Yin, C., & Wen, J.-R. (2021). Contrastive curriculum learning for sequential user behavior modeling via data augmentation. *Proceedings of the 30th ACM International Conference on Information & Knowledge Management*,
- Breese, J. S., Heckerman, D., & Kadie, C. (2013). Empirical analysis of predictive algorithms for collaborative filtering. *arXiv preprint arXiv:1301.7363*.
- Burke, R. (2002). Hybrid recommender systems: Survey and experiments. *User modeling and user-adapted interaction*, 12, 331-370.
- Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. *Proceedings of the IEEE/CVF international conference on computer vision*,
- Chen, J., Dong, H., Wang, X., Feng, F., Wang, M., & He, X. (2023). Bias and debias in recommender system: A survey and future directions. *ACM Transactions on Information Systems*, 41(3), 1-39.
- Chen, K., Liang, B., Ma, X., & Gu, M. (2021). Learning audio embeddings with user listening data for content-based music recommendation. *ICASSP 2021-2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*,
- Chen, T., Kornblith, S., Norouzi, M., & Hinton, G. (2020). A simple framework for contrastive learning of visual representations. *International conference on machine learning*,
- Cheng, H.-T., Koc, L., Harmsen, J., Shaked, T., Chandra, T., Aradhye, H., Anderson, G., Corrado, G., Chai, W., & Ispir, M. (2016). Wide & deep learning for recommender systems. *Proceedings of the 1st workshop on deep learning for recommender systems*,
- Cheng, M., Yuan, F., Liu, Q., Xin, X., & Chen, E. (2021). Learning transferable user representations with sequential behaviors via contrastive pre-training. *2021 IEEE International Conference on Data Mining (ICDM)*,

Reference

- Cui, Z., Xu, X., Fei, X., Cai, X., Cao, Y., Zhang, W., & Chen, J. (2020). Personalized recommendation system based on collaborative filtering for IoT scenarios. *IEEE Transactions on Services Computing*, 13(4), 685-695.
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*.
- Ding, K., Xu, Z., Tong, H., & Liu, H. (2022). Data augmentation for deep graph learning: A survey. *ACM SIGKDD Explorations Newsletter*, 24(2), 61-77.
- Doersch, C., Gupta, A., & Efros, A. A. (2015). Unsupervised visual representation learning by context prediction. Proceedings of the IEEE international conference on computer vision,
- Dogan, O., Kem, F. C., & Oztaysi, B. (2022). Fuzzy association rule mining approach to identify e-commerce product association considering sales amount. *Complex & Intelligent Systems*, 8(2), 1551-1560.
- Fleder, D. M., & Hosanagar, K. (2007). Recommender systems and their impact on sales diversity. Proceedings of the 8th ACM conference on Electronic commerce,
- Ge, M., Delgado-Battenfeld, C., & Jannach, D. (2010). Beyond accuracy: evaluating recommender systems by coverage and serendipity. Proceedings of the fourth ACM conference on Recommender systems,
- Gidaris, S., Singh, P., & Komodakis, N. (2018). Unsupervised representation learning by predicting image rotations. *arXiv preprint arXiv:1803.07728*.
- Goldberg, D., Nichols, D., Oki, B. M., & Terry, D. (1992). Using collaborative filtering to weave an information tapestry. *Communications of the ACM*, 35(12), 61-70.
- Gong, D., Liu, L., Le, V., Saha, B., Mansour, M. R., Venkatesh, S., & Hengel, A. v. d. (2019). Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection. Proceedings of the IEEE/CVF International Conference on Computer Vision,

Reference

- Goyal, P., Dollár, P., Girshick, R., Noordhuis, P., Wesolowski, L., Kyrola, A., Tulloch, A., Jia, Y., & He, K. (2017). Accurate, large minibatch sgd: Training imagenet in 1 hour. *arXiv preprint arXiv:1706.02677*.
- Guan, P., & Lam, E. Y. (2022). Cross-domain contrastive learning for hyperspectral image classification. *IEEE Transactions on Geoscience and Remote Sensing*, 60, 1-13.
- Guo, H., Tang, R., Ye, Y., Li, Z., & He, X. (2017). DeepFM: a factorization-machine based neural network for CTR prediction. *arXiv preprint arXiv:1703.04247*.
- Guo, W., Zhang, C., He, Z., Qin, J., Guo, H., Chen, B., Tang, R., He, X., & Zhang, R. (2022). Miss: Multi-interest self-supervised learning framework for click-through rate prediction. 2022 IEEE 38th International Conference on Data Engineering (ICDE),
- He, T., Zhang, Z., Zhang, H., Zhang, Z., Xie, J., & Li, M. (2019). Bag of tricks for image classification with convolutional neural networks. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,
- He, X., Liao, L., Zhang, H., Nie, L., Hu, X., & Chua, T.-S. (2017). Neural collaborative filtering. Proceedings of the 26th international conference on world wide web,
- Idrissi, N., & Zellou, A. (2020). A systematic literature review of sparsity issues in recommender systems. *Social Network Analysis and Mining*, 10, 1-23.
- Isinkaye, F. O., Folajimi, Y. O., & Ojokoh, B. A. (2015). Recommendation systems: Principles, methods and evaluation. *Egyptian informatics journal*, 16(3), 261-273.
- Juan, Y., Zhuang, Y., Chin, W.-S., & Lin, C.-J. (2016). Field-aware factorization machines for CTR prediction. Proceedings of the 10th ACM conference on recommender systems,
- Kingma, D. P., & Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.

Reference

- Kuchaiev, O., & Ginsburg, B. (2017). Training deep autoencoders for collaborative filtering. *arXiv preprint arXiv:1708.01715*.
- Kunaver, M., & Požrl, T. (2017). Diversity in recommender systems—A survey. *Knowledge-based systems, 123*, 154-162.
- Lam, S. K. T., Frankowski, D., & Riedl, J. (2006). Do you trust your recommendations? An exploration of security and privacy issues in recommender systems. Emerging Trends in Information and Communication Security: International Conference, ETRICS 2006, Freiburg, Germany, June 6-9, 2006. Proceedings,
- Laskin, M., Lee, K., Stooke, A., Pinto, L., Abbeel, P., & Srinivas, A. (2020). Reinforcement learning with augmented data. *Advances in neural information processing systems, 33*, 19884-19895.
- Li, B., Hou, Y., & Che, W. (2022). Data augmentation approaches in natural language processing: A survey. *AI Open, 3*, 71-90.
- Li, B., Li, Y., & Eliceiri, K. W. (2021). Dual-stream multiple instance learning network for whole slide image classification with self-supervised contrastive learning. Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,
- Li, Y., Chen, H., Sun, X., Sun, Z., Li, L., Cui, L., Yu, P. S., & Xu, G. (2021). Hyperbolic hypergraphs for sequential recommendation. Proceedings of the 30th ACM International Conference on Information & Knowledge Management,
- Liang, D., Krishnan, R. G., Hoffman, M. D., & Jebara, T. (2018). Variational autoencoders for collaborative filtering. Proceedings of the 2018 world wide web conference,
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., & Stoyanov, V. (2019). Roberta: A robustly optimized bert pretraining approach. *arXiv preprint arXiv:1907.11692*.
- Liu, Z., Chen, Y., Li, J., Yu, P. S., McAuley, J., & Xiong, C. (2021). Contrastive self-supervised sequential recommendation with robust augmentation. *arXiv preprint arXiv:2108.06479*.

Reference

- Lops, P., De Gemmis, M., & Semeraro, G. (2011). Content-based recommender systems: State of the art and trends. *Recommender systems handbook*, 73-105.
- Marinho, L. B., Nanopoulos, A., Schmidt-Thieme, L., Jäschke, R., Hotho, A., Stumme, G., & Symeonidis, P. (2011). Social tagging recommender systems. *Recommender systems handbook*, 615-644.
- Marlin, B., Zemel, R. S., Roweis, S., & Slaney, M. (2012). Collaborative filtering and the missing at random assumption. *arXiv preprint arXiv:1206.5267*.
- Mikołajczyk, A., & Grochowski, M. (2018). Data augmentation for improving deep learning in image classification problem. 2018 international interdisciplinary PhD workshop (IIPhDW),
- Milojević, S. (2010). Power law distributions in information science: Making the case for logarithmic binning. *Journal of the American Society for Information Science and Technology*, 61(12), 2417-2425.
- Misra, R., Wan, M., & McAuley, J. (2018). Decomposing fit semantics for product size recommendation in metric spaces. Proceedings of the 12th ACM Conference on Recommender Systems,
- Naumov, M., Mudigere, D., Shi, H.-J. M., Huang, J., Sundaraman, N., Park, J., Wang, X., Gupta, U., Wu, C.-J., & Azzolini, A. G. (2019). Deep learning recommendation model for personalization and recommendation systems. *arXiv preprint arXiv:1906.00091*.
- Oyebode, O., & Orji, R. (2020). A hybrid recommender system for product sales in a banking environment. *Journal of Banking and Financial Technology*, 4, 15-25.
- Perez, L., & Wang, J. (2017). The effectiveness of data augmentation in image classification using deep learning. *arXiv preprint arXiv:1712.04621*.
- Pu, P., Chen, L., & Hu, R. (2011). A user-centric evaluation framework for recommender systems. Proceedings of the fifth ACM conference on Recommender systems,

Reference

- Resnick, P., & Varian, H. R. (1997). Recommender systems. *Communications of the ACM*, 40(3), 56-58.
- Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1985). *Learning internal representations by error propagation*.
- Sarwar, B. M. (2001). *Sparsity, scalability, and distribution in recommender systems*. University of Minnesota.
- Sedhain, S., Menon, A. K., Sanner, S., & Xie, L. (2015). Autorec: Autoencoders meet collaborative filtering. Proceedings of the 24th international conference on World Wide Web,
- Shao, B., Li, X., & Bian, G. (2021). A survey of research hotspots and frontier trends of recommendation systems from the perspective of knowledge graph. *Expert Systems with Applications*, 165, 113764.
- Shenbin, I., Alekseev, A., Tutubalina, E., Malykh, V., & Nikolenko, S. I. (2020). Recvae: A new variational autoencoder for top-n recommendations with implicit feedback. Proceedings of the 13th international conference on web search and data mining,
- Shorten, C., & Khoshgoftaar, T. M. (2019). A survey on image data augmentation for deep learning. *Journal of big data*, 6(1), 1-48.
- Son, J., & Kim, S. B. (2017). Content-based filtering for recommendation systems using multiattribute networks. *Expert Systems with Applications*, 89, 404-412.
- Steck, H. (2013). Evaluation of recommendations: rating-prediction and ranking. Proceedings of the 7th ACM conference on Recommender systems,
- Takahashi, R., Matsubara, T., & Uehara, K. (2019). Data augmentation using random image cropping and patching for deep CNNs. *IEEE Transactions on Circuits and Systems for Video Technology*, 30(9), 2917-2931.

Reference

- Tschannen, M., Bachem, O., & Lucic, M. (2018). Recent advances in autoencoder-based representation learning. *arXiv preprint arXiv:1812.05069*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- Wang, X., Liu, N., Han, H., & Shi, C. (2021). Self-supervised heterogeneous graph neural network with co-contrastive learning. Proceedings of the 27th ACM SIGKDD conference on knowledge discovery & data mining,
- Wei, Y., Wang, X., Li, Q., Nie, L., Li, Y., Li, X., & Chua, T.-S. (2021). Contrastive learning for cold-start recommendation. Proceedings of the 29th ACM International Conference on Multimedia,
- Wu, J., Wang, X., Feng, F., He, X., Chen, L., Lian, J., & Xie, X. (2021). Self-supervised graph learning for recommendation. Proceedings of the 44th international ACM SIGIR conference on research and development in information retrieval,
- Wu, L., Lin, H., Tan, C., Gao, Z., & Li, S. Z. (2021). Self-supervised learning on graphs: Contrastive, generative, or predictive. *IEEE Transactions on Knowledge and Data Engineering*.
- Wu, S., Sun, F., Zhang, W., Xie, X., & Cui, B. (2022). Graph neural networks in recommender systems: a survey. *ACM Computing Surveys*, 55(5), 1-37.
- Wu, Z., Pan, S., Chen, F., Long, G., Zhang, C., & Philip, S. Y. (2020). A comprehensive survey on graph neural networks. *IEEE transactions on neural networks and learning systems*, 32(1), 4-24.
- Xie, X., Sun, F., Liu, Z., Wu, S., Gao, J., Zhang, J., Ding, B., & Cui, B. (2022). Contrastive learning for sequential recommendation. 2022 IEEE 38th international conference on data engineering (ICDE),
- Yan, C., Chen, Y., & Zhou, L. (2019). Differentiated fashion recommendation using knowledge graph and data augmentation. *IEEE access*, 7, 102239-102248.

Reference

- Yang, L., Li, Y., Wang, J., & Sherratt, R. S. (2020). Sentiment analysis for E-commerce product reviews in Chinese based on sentiment lexicon and deep learning. *IEEE access*, 8, 23522-23530.
- Yang, Y., Huang, C., Xia, L., & Li, C. (2022). Knowledge graph contrastive learning for recommendation. Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval,
- Yao, T., Yi, X., Cheng, D. Z., Yu, F., Chen, T., Menon, A., Hong, L., Chi, E. H., Tjoa, S., & Kang, J. (2021). Self-supervised learning for large-scale item recommendations. Proceedings of the 30th ACM International Conference on Information & Knowledge Management,
- Yin, H., Cui, B., Li, J., Yao, J., & Chen, C. (2012). Challenging the long tail recommendation. *arXiv preprint arXiv:1205.6700*.
- You, Y., Chen, T., Sui, Y., Chen, T., Wang, Z., & Shen, Y. (2020). Graph contrastive learning with augmentations. *Advances in neural information processing systems*, 33, 5812-5823.
- Yu, J., Yin, H., Xia, X., Chen, T., Li, J., & Huang, Z. (2022). Self-supervised learning for recommender systems: A survey. *arXiv preprint arXiv:2203.15876*.
- Zhang, J., Gao, M., Yu, J., Guo, L., Li, J., & Yin, H. (2021). Double-scale self-supervised hypergraph learning for group recommendation. Proceedings of the 30th ACM International Conference on Information & Knowledge Management,
- Zhang, S., Yao, L., Sun, A., & Tay, Y. (2019). Deep learning based recommender system: A survey and new perspectives. *ACM computing surveys (CSUR)*, 52(1), 1-38.
- Zhou, D., Hao, S., Zhang, H., Dai, C., An, Y., Ji, Z., & Ganchev, I. (2021). Novel SDDM rating prediction models for recommendation systems. *IEEE access*, 9, 101197-101206.